



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos
Masivos/ Visual Analytics and Big Data

Influencia de Variables en el Precio de las Habitaciones en Hoteles Españoles

Trabajo fin de estudio presentado por:	Durán Porras, Pedro Jiménez Lázaró, Manuel Moyano González, Alejandro
Tipo de trabajo:	Piloto experimental
Director/a:	Padilla García, Manuel
Fecha:	23/07/2025

Resumen

Este trabajo analiza los factores que influyen en el precio de alojamientos turísticos en España y desarrolla modelos predictivos a partir de un conjunto de datos obtenido de Booking.com, que incluye variables como reputación, tamaño de la habitación y ubicación. La investigación se estructura en tres fases: análisis exploratorio y visualización, implementación de modelos predictivos y comparación de resultados mediante métricas MAE, RMSE y R^2 . Se han aplicado modelos de regresión lineal, algoritmos basados en árboles (Random Forest, XGBoost) y redes neuronales en TensorFlow. Los resultados evidencian que Random Forest alcanzó el mejor rendimiento ($R^2 = 0,88$, MAE = 27,82), seguido de la red neuronal optimizada ($R^2 = 0,83$), mientras que los modelos lineales ofrecieron valores inferiores ($R^2 = 0,46$). Entre las variables, la reputación global y el área del alojamiento mostraron mayor influencia, frente a variables menos determinantes como la disponibilidad de *WiFi*. En conclusión, los métodos no lineales son más eficaces para este problema, destacando la importancia de la reputación y el tamaño en la determinación de precios, lo que aporta valor tanto para la investigación como para la toma de decisiones estratégicas en el sector hotelero.

Palabras clave: Análisis exploratorio de datos, Random Forest, XGBoost, Redes Neuronales, Machine Learning

Abstract

This study analyzes the factors influencing hotel room prices in Spain and develops predictive models using a dataset from Booking.com, which includes variables such as reputation, room size, and location. The research is organized into three stages: exploratory data analysis and visualization, implementation of predictive models, and comparison of results through MAE, RMSE, and R^2 metrics. The models applied include linear regression, tree-based algorithms (Random Forest, XGBoost), and neural networks in TensorFlow. Results show that Random Forest achieved the highest performance ($R^2 = 0.88$, MAE = 27.82), followed by the optimized neural network ($R^2 = 0.83$), while linear models yielded lower accuracy ($R^2 = 0.46$). Variable importance analysis indicates that global reputation and room size exert the greatest influence, whereas features like free WiFi had minimal impact. In conclusion, non-linear models demonstrate superior predictive power for this problem, highlighting the relevance of reputation and size in price determination and providing practical insights for strategic decision-making in the hospitality sector.

Keywords: Exploratory Data Analysis, Random Forest, XGBoost, Artificial Neural Networks, Machine Learning

Índice de contenidos

1.	Introducción	1
1.1.	Motivación	2
1.2.	Planteamiento del trabajo	4
1.3.	Estructura del trabajo	5
2.	Contexto y estado del arte	8
2.1.	Contexto del problema	8
2.2.	Estado del arte	12
2.2.1.	Modelos hedónicos	13
2.2.2.	Aprendizaje automático y análisis de series temporales	15
2.2.3.	Factores que influyen en los precios	19
2.2.4.	Trabajos que aplican técnicas de ML y redes neuronales en otros ámbitos ...	22
2.3.	Conclusiones	25
3.	Objetivos concretos y metodología de trabajo	28
3.1.	Objetivo general	28
3.2.	Objetivos específicos	29
3.3.	Metodología del trabajo	29
4.	Marco normativo	32
5.	Desarrollo específico de la contribución	34
5.1.	Exploración y Análisis de Datos	34
5.1.1.	Carga de datos y limpieza inicial	35
5.1.2.	Análisis de estructura y calidad del conjunto de datos	36
5.1.3.	Estadística descriptiva general y tratamiento de valores atípicos	42
5.1.4.	Análisis gráfico de cada variable y estudio de correlaciones	44
5.1.5.	Análisis regional del precio de los alojamientos	47

5.1.6.	Comparación regional del impacto de las variables reputación y área	54
5.1.7.	Influencia de la reputación en Booking sobre el precio: análisis predictivo	55
5.2.	Modelado predictivo del precio	58
5.2.2.	Transformaciones del conjunto de datos para el modelado	60
5.2.3.	Modelos tradicionales	62
5.2.4.	Modelos avanzados de aprendizaje automático.....	65
5.2.5.	Modelos basados en redes neuronales.....	66
6.	Análisis y comparación de modelos	77
6.1.	Comparativa de métricas de evaluación	77
6.2.	Visualización de predicciones y selección final	78
7.	Código fuente y datos analizados	80
7.1.	Código fuente	80
7.2.	Datos Analizados	81
7.3.	Estructura general del repositorio	81
8.	Conclusiones.....	83
8.1.	Interpretación de resultados y comparación de modelos	84
8.2.	Hiperparámetros clave	85
8.3.	Reflexión final sobre eficiencia y coste computacional	85
9.	Limitaciones y prospectiva	88
9.1.	Limitaciones.....	88
9.2.	Trabajo futuro.....	89
	Referencias bibliográficas.....	91

Índice de figuras

Figura 1. Logo empresa Booking.com.....	1
Figura 2. Esquema sencillo de la metodología propuesta	5
Figura 3. Proceso del Revenue Management (RM).....	9
Figura 4. Ingresos por habitaciones del hotel Courtyard by Marriott	11
Figura 5. Entendimiento modelos SARIMA y ARIMA.	15
Figura 6. Estructura modelo MS-STF.	16
Figura 7. Clasificación de las redes neuronales según Abiodun et al. (2018).....	25
Figura 8. Número de registros en el dataset usado.....	35
Figura 9. Imagen de las variables usadas del dataset	37
Figura 10. Distribución de la variable precio	44
Figura 11. Boxplot de la variable precio	44
Figura 12. Mapa de división de regiones utilizadas.....	47
Figura 13. Influencia de la reputación sobre el Precio.....	57
Figura 14. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Simple para la predicción del precio de alojamientos turísticos.	71
Figura 15. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Mejorada para la predicción del precio de alojamientos turísticos.	72
Figura 16. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Final para la predicción del precio de alojamientos turísticos.	73
Figura 17. Comparación de predicción de modelos con valor real de precio	79
Figura 18. Esquema del repositorio	82

Índice de tablas

Tabla 1. <i>Organización del trabajo en grupo.</i>	IX
Tabla 2. <i>Cantidad de faltantes por variable</i>	41
Tabla 3. <i>Tabla de correlaciones por regiones</i>	55
Tabla 4. <i>Resultados influencia reputación con diferentes modelos</i>	56
Tabla 5. <i>Resultados del grado de influencia de la reputación sobre el precio</i>	58
Tabla 6. <i>Resultados en diferentes métricas con la red neuronal avanzada</i>	70
Tabla 7. <i>Comparativa de resultados en diferentes modelos</i>	77
Tabla 8. <i>Tabla de métricas de los modelos entrenados</i>	87

Organización del trabajo en grupo

Una buena organización del trabajo previo y durante su desarrollo es parte fundamental de cualquier labor con un componente científico o ingenieril. Sería inviable llevar un sistema de software a producción o levantar los cimientos de un edificio sin una planificación anterior. Es por eso por lo que en este apartado se detallarán las distintas partes en las que se ha dividido este trabajo, los objetivos que se persiguen en cada una de ellas y cómo se coordinan los distintos miembros del grupo.

Partes que aborda el TFE

A pesar de que los miembros de este TFM han formado un grupo compacto que trabaja por igual en muchas de las tareas, cada componente tiene un área de especialización única que permite a este trabajo desarrollarse de forma completa.

Por una parte, Pedro Durán, graduado en Matemáticas, se encargará de realizar un estudio en detalle del *dataset* de entrada. Este estudio constará de un análisis estadístico de diferentes formas con el objetivo de obtener un conocimiento previo avanzado de los datos, junto con la muestra de diferentes métricas y visualizaciones que acompañen de forma gráfica.

Por otro lado, Manuel Jiménez, ingeniero informático, se especializará en la aplicación de técnicas de *Machine Learning* (ML) no relacionadas con redes neuronales. El objetivo principal es tratar de obtener uno o varios modelos útiles, ya sean lineales o no lineales, que permitan la predicción del precio de una habitación de hotel en función de las características de este.

En última instancia, Alejandro Moyano, ingeniero biomédico, será el encargado de aplicar también modelos de ML pero enfocadas en redes neuronales y *Deep Learning* (DL). Su tarea consistirá en desarrollar modelos capaces de capturar patrones no lineales complejos en los datos, con el fin de evaluar si estas metodologías más sofisticadas pueden superar en precisión a los enfoques clásicos previamente desarrollados. Esta comparación entre técnicas permitirá enriquecer significativamente el contenido del Trabajo de Fin de Máster (TFM), aportando una visión crítica y fundamentada sobre las ventajas y limitaciones de cada enfoque.

Distribución y estructura de la memoria

En la siguiente tabla se releja el reparto de trabajo a la hora de redactar y organizar esta memoria.

Tabla 1. *Organización del trabajo en grupo.*

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	Responsables
Introducción	P. Durán, M. Jiménez y A. Moyano
Contexto y estado del arte	P. Durán, M. Jiménez y A. Moyano
Objetivos y metodología de trabajo	P. Durán, M. Jiménez y A. Moyano
Marco normativo	P. Durán, M. Jiménez y A. Moyano
Visualización, métricas y análisis estadístico	P. Durán
Modelos e hiperparámetros que no son redes neuronales	M. Jiménez
Modelos e hiperparámetros que son redes neuronales	A. Moyano
Conclusiones	P. Durán, M. Jiménez y A. Moyano

Fuente: Elaboración propia.

Objetivo del TFE desde el punto de vista de la adquisición de conocimientos

El objetivo formativo de este TFM es doble: por un lado, conocer y profundizar en técnicas de análisis de datos y modelado predictivo aplicadas al sector hotelero; por otro, garantizar que cada miembro del equipo adquiriera una visión global del proyecto más allá de su especialidad concreta.

En la primera fase, liderada por Pedro Durán, se trabajará sobre el estudio exploratorio del conjunto de datos extraídos del *dataset* proporcionado. El propósito no es solo aplicar herramientas de estadística descriptiva, cálculo de medias, medianas o desviaciones estándar, sino también interiorizar su interpretación y aprender a detectar patrones, tendencias y

posibles anomalías que puedan condicionar los modelos posteriores. A través de ejercicios prácticos en Python, se desarrollarán habilidades en limpieza de datos, tratamiento de valores atípicos y generación de visualizaciones -histogramas, diagramas de cajas, mapas de calor- orientadas a comunicar resultados de forma clara y comprensible.

La segunda etapa, a cargo de Manuel Jiménez, se centra en la construcción de modelos de *machine learning* clásicos, como la Regresión Lineal o Ridge, así como otros más modernos como XGBoost y Random Forest. Más allá de la implementación de estos algoritmos con la librería Scikit-learn, el objetivo formativo reside en comprender los procesos de validación cruzada, ajuste de hiperparámetros y prevención de sobreajuste. Evaluar los resultados mediante métricas como *MAE*, *RMSE*, *MSE* y R^2 enseñará a extraer conclusiones prácticas sobre la precisión y utilidad de cada enfoque, así como a presentarlas apoyadas en gráficos que faciliten la interpretación incluso para perfiles no técnicos.

Finalmente, en la fase de comparación de algoritmos, liderada por Alejandro Moyano, se explorarán arquitecturas de redes neuronales densas utilizando librerías de Python como Keras. El aprendizaje se centrará en el diseño y configuración de modelos, el uso de técnicas de regularización como *dropout* y la aplicación de estrategias para evitar el sobreajuste. El reto consiste en evaluar si estas metodologías capturan patrones no lineales complejos que mejoren la capacidad predictiva respecto a los modelos clásicos.

Para asegurar que nadie se quede anclado únicamente en su área, el equipo celebrará semanalmente sesiones de revisión cruzada en las que cada miembro presentará sus avances, dificultades y hallazgos. De igual modo, se mantendrá un documento vivo compartido que recoja la metodología, los resultados preliminares y las decisiones de modelado, fomentando que todos aporten y revisen las contribuciones de los demás. Además, se organizarán talleres internos donde cada responsable transmitirá al grupo los conocimientos clave de su fase: Pedro en estadística y visualización, Manuel en pipelines de *ML* y Alejandro en construcción y depuración de redes neuronales.

Al concluir el proyecto, cada integrante no solo habrá dominado técnicas de análisis y modelado predictivo, sino también desarrollado el pensamiento crítico necesario para identificar variables relevantes, la capacidad técnica para llevar un flujo de datos desde su

preprocesamiento hasta la evaluación de modelos y la habilidad de comunicar resultados de forma efectiva mediante visualizaciones y métricas. Asimismo, la experiencia colaborativa reforzará competencias transversales como la gestión de proyectos, la documentación técnica y el trabajo en equipo, aportando un perfil profesional integral y preparado para los retos del sector hotelero y más allá.

Mecanismos de coordinación empleados

El desarrollo del TFM en modalidad grupal representa una gran oportunidad para simular dinámicas reales en el entorno laboral, donde el trabajo colaborativo, la coordinación entre perfiles diversos y la toma de decisiones conjunta constituyen pilares fundamentales. En este sentido, a lo largo del presente proyecto, se han empleado una serie de mecanismos, herramientas y buenas prácticas orientas a facilitar la comunicación fluida, la distribución eficiente de tareas y el cumplimiento de los plazos establecidos, garantizando en todo momento la coherencia y la calidad del trabajo conjunto.

Herramientas digitales de comunicación

La comunicación ha sido uno de los elementos clave para el buen desarrollo del TFM. Debido a que los miembros del equipo residen en diferentes ubicaciones geográficas y disponen de horarios dispares, se hizo imprescindible adoptar herramientas digitales que permitieran una comunicación asincrónica y sincrónica eficiente.

Para la comunicación diaria y la resolución rápida de dudas, se utilizó principalmente WhatsApp, dado su carácter inmediato y accesibilidad en dispositivos móviles. Esta vía permitió mantener una comunicación continua sobre avances, incidencias, propuestas y confirmación de tareas completadas tanto cuando se ha trabajado de forma grupal como cuando se ha trabajado por separado.

Además, se empleó Discord, para realizar reuniones periódicas (cada semana) en las que se exponían los avances tomados individualmente, se discutían decisiones clave del proyecto y se acordaban los siguientes pasos a seguir. Estas reuniones, que solían tener una duración de aproximadamente, entre 1-2 horas, también se aprovechaban para resolver dudas técnicas más complejas y garantizar que todos los miembros estuvieran alineados respecto a la evolución del trabajo.

Por otro lado, en momentos clave -como la entrega de los borradores o la integración de resultados parciales- se utilizaron videollamadas más extensas, por Google Meet, con un enfoque claramente operativo, orientadas a la puesta en común de resultados y a la depuración de errores o incoherencias, con la ayuda de nuestro tutor del TFM, Manuel Padilla.

Gestión del trabajo y reparto de tareas

Con el fin de mantener una organización clara de los archivos, de responsabilidades, de bloques en los que se ha estructurado el proyecto y tareas individuales, se hizo uso de Google Drive, donde, desde las primeras fases del proyecto, se han ido acumulando toda la información utilizada, y por utilizar que sean relevantes.

Además, a modo de borrador, se repartieron de forma general, inicialmente, las tareas que cada miembro del grupo de trabajo desempeñaría a lo largo de este trabajo. Así, cada integrante asumió responsabilidades diferenciadas según su perfil formativo y experiencia previa, como ya se expuso en el apartado correspondiente a la organización del trabajo. Sin embargo, se fomentó también la colaboración cruzada, revisando y comentado el trabajo de los demás miembros para garantizar una mayor cohesión y calidad del producto final.

Para el seguimiento de tareas y control de versiones, se hizo uso del entorno colaborativo de Microsoft 365, que nos permitió crear diferentes archivos, como *.docx* y *.xlsx*, donde trabajamos de forma simultánea sobre la misma documentación, facilitando las correcciones, comentarios y aportaciones en tiempo real.

Control de versiones y trabajo técnico

Uno de los aspectos más desafiantes en un trabajo grupal con contenido técnico y programático es el control de versiones y la integración del código por los distintos integrantes del equipo. Aunque en un entorno profesional suele ser habitual el uso de sistemas de control de versiones como GitHub, en este caso se optó por un enfoque más sencillo y accesible, adaptado a las herramientas con las que cada miembro se sentía más cómodo.

Para ello, se utilizó, como se ha mencionado anteriormente, Google Drive, como repositorio compartido principal, donde se fueron almacenando y actualizando los diferentes archivos de trabajo. Esta estructura permitía tener una organización por carpetas según las fases del proyecto (preprocesamiento de los datos, análisis exploratorio de los datos, visualizaciones, etc.) lo que facilitó la localización y reutilización de *scripts* y *notebooks*. Además, cada archivo

incluía en su nombre la fecha de la última modificación y una breve descripción, ayudando así a evitar confusiones y solapamientos entre las versiones.

El trabajo técnico se desarrolló de forma local en los entornos preferidos por cada miembro del equipo, siendo los más utilizados Visual Studio Code (VS Code) y Anaconda con Jupyter Notebook. Esta flexibilidad permitió aprovechar las ventajas de cada plataforma, según las necesidades para cada fase del proyecto y el tipo de análisis que se estuviera realizando, además de por preferencia por parte del integrante del equipo que lo usara. Por ejemplo, mientras algunos análisis exploratorios y visualizaciones se llevaban a cabo directamente en *notebooks* por su carácter interactivo, el desarrollo de modelo de ML más complejos o la ejecución de *scripts* completos se realizó en entornos más estructurados como VS Code.

Aunque no se implementó un control de versiones automatizado, se promovió una comunicación constante entre los integrantes para coordinar qué archivos estaban siendo modificados por cada persona, evitando así conflictos de sobreescritura. También se realizaron revisiones cruzadas de los *notebooks* más relevantes, asegurando la coherencia de los enfoques utilizados y permitiendo identificar posibles errores o mejoras.

Coordinación documental y versiones del informe

La redacción del informe final del TFM fue también una tarea que requirió una coordinación específica. Se adoptó como herramienta principal Word, por su capacidad para trabajar de manera colaborativa, controlar versiones automáticamente y permitir comentarios en línea que facilitan la revisión cruzada entre los miembros del equipo.

Para asegurar una estructura coherente, se creó un índice general compartido que fue evolucionando a medida que se completaban los distintos apartados. Se acordó también un estilo común de redacción (además de seguir una plantilla facilitada por la universidad con diferentes *presets* para títulos y tabulaciones), que fue respetado durante la escritura del documento. Cada sección fue inicialmente desarrollada por el integrante más directamente relacionado con el contenido técnico correspondiente, pero posteriormente fue revisada y trabajada por el resto de los integrantes del equipo, para así detectar errores, mejoras de claridad y asegurar la coherencia con el resto del texto.

Asimismo, se realizaron varias iteraciones de revisión y mejora en función del *feedback* recibido tanto de los compañeros como del tutor del trabajo. Estas revisiones fueron

gestionadas mediante comentarios integrados y sugerencias en los diferentes borrados creados del proyecto, permitiendo una mejora continua del documento sin sobrescribir versiones anteriores.

Colaboración con el tutor académico

Además de la coordinación interna entre los miembros del grupo, se mantuvo una comunicación constante con el tutor académico del TFM, quien proporcionó una supervisión metodológica y conceptual muy valiosa. Esta colaboración se gestionó mediante correos electrónicos periódicos, reuniones puntuales a través de videollamadas y la entrega escalonada de borradores para revisión.

El tutor ha sido clave para validar las decisiones metodológicas, revisar la estructura del documento, proponer mejoras y orientar sobre posibles líneas de trabajo que enriquecieran el análisis o permitieran una mejor presentación de los resultados. Esta figura funcionó también como un nexo entre los requerimientos académicos del máster y el enfoque aplicado que se quería dar al trabajo, ayudando a mantener el equilibrio entre el rigor científico y la utilidad práctica del TFM.

1. Introducción

El presente Trabajo Fin de Máster (TFM) se enmarca en el contexto actual de digitalización del sector turístico, en el que los datos generados por los usuarios y las plataformas de reservas online han adquirido un papel determinante en la toma de decisiones empresariales (Lamest & Brady, 2018). En particular, la capacidad de fijar precios adecuados para habitaciones de hotel y otros alojamientos se ha convertido en un factor clave de competitividad en un mercado cada vez más dinámico, transparente y orientado al cliente (Abrate et al., 2011). De hecho, un mal ajuste de precios en un hotel puede suponer la pérdida de miles de euros a la vez que la pérdida de parte de su reputación online, debido a las malas reseñas que los huéspedes publiquen en la web.

A partir de esta realidad, este trabajo propone un enfoque basado en ciencia de datos y técnicas de aprendizaje automático para analizar y predecir el precio de habitaciones de alojamientos turísticos en España. La idea central es explorar cómo diferentes factores -como la reputación online, la localización, la categoría del alojamiento o la temporalidad- influyen en el precio final que se ofrece al cliente, y cómo esta información puede ser utilizada para construir modelos predictivos útiles tanto para el análisis académico como para la gestión empresarial.

Figura 1. Logo empresa Booking.com



Fuente: Siguiendo [enlace](#)

El estudio se apoya en un amplio conjunto de datos reales extraídos de la plataforma Booking.com (ver Figura 1), lo que permite trabajar con una muestra representativa y actual del mercado. A través de una metodología estructurada que incluye el análisis exploratorio de datos, la visualización de patrones relevantes y la implementación de modelos de predicción

como regresión, árboles de decisión y redes neuronales, se busca comprender las relaciones entre variables e identificar cuáles son los factores que más influyen en el precio de una habitación.

En relación a la elección de la plataforma a través de la que se extraen los datos. Se ha seleccionado Booking.com por su dominancia en el mercado hotelero -muchos hoteles recurren a Booking.com como método de promoción y venta online prioritario- y por la disponibilidad que poseíamos de los datos analizados, provenientes de una empresa colaboradora. Aunque los resultados se presentarán más adelante, el propósito general es claro: ofrecer una herramienta analítica que permita estimar precios con precisión, pero también proporcionar una lectura interpretativa de los datos que ayude a los gestores hoteleros a tomar decisiones estratégicas basadas en evidencia. En definitiva, este TFM aspira a contribuir al conocimiento aplicado en el ámbito del *pricing*¹ hotelero, integrando enfoques cuantitativos con una perspectiva orientada a la mejora de la competitividad en un entorno digital.

En los siguientes apartados dentro de este primer capítulo se va a seguir introduciendo el trabajo. Primeramente, en el apartado 1.1, se va a presentar la problemática que se abordará y las motivaciones que convierten a este proyecto en un desarrollo interesante para la industria hotelera. En el 1.2, por otra parte, se describirán los objetivos que se plantean y cómo se pretenden alcanzar. Por último, el apartado 1.3 se centra en explicar la organización de este documento y cómo se va a ir abordando.

1.1.Motivación

La creciente importancia del turismo en la economía española y la intensa competencia en el sector hotelero han motivado a los establecimientos turísticos a desarrollar estrategias innovadoras para optimizar sus ingresos. Uno de los mayores desafíos que enfrentan es determinar con precisión el precio adecuado por habitación, una tarea compleja que depende de múltiples variables internas y externas, incluyendo las características propias del

¹ Pricing: término en inglés que hace referencia a la fijación de precios o a la estrategia empleada para determinar el precio óptimo de un producto o servicio

alojamiento y especialmente la reputación online (Ye et al., 2008; Vermeulen & Seegers, 2008).

El presente Trabajo de Fin de Máster (TFM) aborda la problemática que enfrentan los gestores hoteleros para predecir y fijar el precio óptimo de las habitaciones debido a la alta variabilidad e incertidumbre de la demanda, así como al peso creciente de las opiniones y valoraciones publicadas en plataformas digitales, destacando especialmente la importancia actual de Booking.com. Esta plataforma, líder mundial en reservas hoteleras online, proporciona un volumen significativo de información relevante sobre alojamientos, influyendo considerablemente en las decisiones de compra de los usuarios y, en consecuencia, en la estrategia comercial y la rentabilidad de los establecimientos hoteleros (Xie et al., 2014; Ert et al., 2016).

Las causas principales del problema radican en la ausencia o insuficiencia de herramientas analíticas avanzadas capaces de integrar y procesar eficientemente datos multidimensionales, como ubicación, categoría, servicios ofrecidos por el alojamiento y métricas detalladas sobre reputación online (Öğüt y Onur Taş, 2011). Habitualmente, la fijación de precios se ha realizado mediante métodos intuitivos o análisis limitados, desaprovechando así la riqueza informativa contenida en los grandes volúmenes de datos disponibles en plataformas digitales.

La relevancia científica y práctica de este problema reside en la necesidad de aportar soluciones analíticas rigurosas que permitan no solamente predecir con precisión los precios, sino también detectar la influencia específica de cada factor involucrado. Este análisis puede ser especialmente útil para que los gestores hoteleros identifiquen qué características concretas del alojamiento pueden modificarse o mejorarse para lograr un impacto positivo en el precio por habitación, aumentando así directamente sus ingresos (Abrate & Viglia, 2016; Sparks & Browning, 2011). Cabe señalar que este estudio utiliza exclusivamente información a nivel agregado de los establecimientos, sin considerar datos personales específicos de los clientes.

Por último, el presente trabajo también busca ofrecer resultados de relevancia comercial inmediata, proporcionando herramientas prácticas y aplicables para optimizar estrategias de gestión hotelera. De esta forma, se pretende contribuir no solo al ámbito académico y

científico, sino también al fortalecimiento competitivo del sector hotelero español (Zhang et al., 2011).


1.2. Planteamiento del trabajo

Partiendo del contexto anteriormente descrito, la problemática principal que se pretende abordar en este TFM radica en la dificultad que enfrentan los establecimientos hoteleros a la hora de predecir y optimizar los precios de sus habitaciones. Esta dificultad proviene, fundamentalmente, de la complejidad inherente a la combinación de múltiples variables - tanto internas como externas- que influyen en la fijación de precios, como la reputación online, la ubicación geográfica, la categoría del alojamiento, la estacionalidad, o las características de la oferta, entre muchas otras.

Ante este reto, el presente trabajo propone como solución el diseño y desarrollo de un sistema de modelado predictivo que permita estimar de forma precisa el precio óptimo por habitación. Para ello, se recurrirá a modelos de aprendizaje automático, capaces de identificar patrones en grandes volúmenes de datos y de proporcionar predicciones robustas y fundamentadas. Se emplearán técnicas como la regresión lineal, los árboles de decisión y las redes neuronales, modelos que han demostrado una alta eficacia en escenarios con múltiples variables explicativas (James et al., 2013).

La propuesta metodológica se sustenta en el uso de un conjunto de datos reales obtenidos mayoritariamente de Booking.com, una de las principales plataformas de reservas hoteleras a nivel mundial. Estos datos serán sometidos a un riguroso proceso de tratamiento, limpieza, transformación y análisis para garantizar su validez y aprovechamiento (ver Figura 2 adjunta).

Figura 2. Esquema sencillo de la metodología propuesta



Fuente: Elaboración propia

A través de este enfoque, se pretende no solo predecir precios, sino también descomponer y cuantificar la influencia individual de cada variable considerada en el estudio.

El objetivo último del trabajo es proporcionar una herramienta de apoyo a la toma de decisiones que sea comprensible, interpretable y útil para los gestores del sector hotelero. Esta herramienta permite identificar qué aspectos de su oferta pueden ajustarse o potenciarse para mejorar la competitividad y maximizar los ingresos por habitación. Además, se busca que la solución desarrollada pueda integrarse fácilmente en plataformas tecnológicas ya existentes o, en su defecto, desplegarse como una aplicación independiente adaptada a las necesidades del entorno empresarial actual. El hecho de que la investigación suponga un beneficio real para el sector hotelero potencia el resultado de este TFM y supone un factor motivante para el desarrollo de éste.

De esta forma, el presente TFM no solo tiene una vocación académica, al contribuir al estudio de la predicción de precios mediante técnicas de ciencia de datos, sino también una clara orientación práctica, al aportar soluciones reales a un problema cotidiano en el sector turístico y hotelero en España.

1.3. Estructura del trabajo

El presente TFM se organiza en una serie de capítulos diseñados para abordar de manera progresiva y coherente la problemática planteada, facilitando tanto su comprensión teórica como su resolución práctica. La estructura adoptada permite guiar al lector desde la

contextualización inicial hasta el desarrollo de modelos predictivos y la obtención de conclusiones con aplicabilidad real en el sector hotelero.

El Capítulo 2 ofrece una revisión fundamentada de estudios previos relacionados con la fijación de precios en alojamientos turísticos, abordando enfoques clásicos como los modelos hedónicos, así como metodologías más recientes basadas en aprendizaje automático y análisis de series temporales. Esta sección proporciona el marco teórico que sustenta las decisiones técnicas tomadas a lo largo del trabajo.

El Capítulo 3 establece con precisión el objetivo general y los objetivos específicos que guían la investigación. Asimismo, describe la metodología empleada para alcanzar dichos fines, incluyendo el proceso de limpieza, análisis exploratorio, desarrollo de modelos y evaluación de resultados, con una justificación detallada de las técnicas y herramientas utilizadas.

En el Capítulo 4 se abordan las implicaciones legales y éticas relacionadas con el uso de datos, poniendo especial atención en el cumplimiento de la normativa vigente en materia de protección de datos, así como en las garantías adoptadas para preservar la confidencialidad y trazabilidad de la información utilizada.

Los Capítulos 5 y 6 constituyen el núcleo práctico del trabajo. En el Capítulo 5 se desarrolla un análisis exploratorio detallado del conjunto de datos, acompañado de visualizaciones, estadísticas descriptivas y estudios regionales que permiten entender las dinámicas de precios en distintos contextos. Posteriormente, en este capítulo, se explica el entrenamiento de los diferentes modelos. A continuación, el Capítulo 6 compara el rendimiento general de diferentes enfoques, desde modelos tradicionales hasta redes neuronales profundas, con el objetivo de identificar cuáles son los más precisos y robustos en este escenario.

En el Capítulo 7 se centra en exponer el código desarrollado durante la realización del trabajo. Finalmente, el Capítulo 8 recoge las principales conclusiones extraídas del trabajo, destacando los hallazgos más relevantes, y se enlaza con el Capítulo 9, que destaca las limitaciones encontradas y proponiendo posibles líneas de mejora y evolución futura del sistema desarrollado. Esta estructura responde al propósito de ofrecer un análisis riguroso, sistemático y aplicable, alineado con las exigencias académicas del máster y con los retos actuales del sector turístico en un entorno cada vez más orientado a los datos.

Tras esta pormenorizada revisión de los capítulos que se desarrollan a lo largo del documento, se procede en el siguiente capítulo a describir el contexto en torno al que gira el trabajo y el estado del arte relacionado.

2. Contexto y estado del arte

Una vez expuesto el propósito del estudio, resulta esencial presentar el estado del arte para situar la investigación en su marco teórico y metodológico. Con ese fin, la revisión se articula en tres secciones claramente diferenciadas.

El primero de ellos es el contexto del problema. En él se argumenta por qué el objeto de estudio constituye un problema de investigación relevante.

Tras esto, sigue la sección del propio estado del arte, donde se analizan soluciones propuestas sobre la misma temática. Estas pueden ser soluciones que utilicen las mismas técnicas u otras diferentes, siempre y cuando posean una relación significativa con el ámbito del proyecto.


Por último, se obtienen diversas conclusiones según lo encontrado de cara a la propia labor de investigación y desarrollo del trabajo.

2.1.Contexto del problema

La industria hotelera se caracteriza por su dinamismo y competitividad (López-Gamero et al., 2023), donde la fijación adecuada de precios es crucial para maximizar los ingresos y mantener la competitividad en el mercado (Abrate et al., 2011). Los precios de las habitaciones de hotel no solo reflejan los costos operativos, sino también una variedad de factores que incluyen las características del hotel, la demanda del mercado, la estacionalidad, la ubicación geográfica, la categoría del hotel, las puntuaciones en línea y las políticas de cancelación, entre otros (Sánchez-Pérez et al., 2019). Estos factores se definen con más detalle a lo largo de este documento.

Tradicionalmente, los hoteles han utilizado estrategias de gestión de ingresos, también conocidas como *Revenue Management* (RM) (ver Figura 3, donde se muestra en pasos las estrategias y tácticas del proceso de RM), para ajustar los precios en función de la demanda anticipada y la disponibilidad (Ivanov & Zhechev, 2012). Estas técnicas de RM surgieron en los años 60 en las aerolíneas, cuando Kosten (1960) desarrolló el primer modelo formal para optimizar la venta de billetes frente a la incertidumbre de las cancelaciones y los *no-shows*.

Figura 3. Proceso del Revenue Management (RM).



Fuente: Ver siguiente [enlace](#).

Littlewood (1972) propuso aceptar billetes con tarifa reducida siempre que su ingreso esperado superase el ingreso de plazas de tarifa completa aún no vendidas. Esta regla, conocida como la regla de Littlewood, fue el germen del *yield management*, sistema de gestión de precios e inventario basado en la anticipación del comportamiento del consumidor para optimizar la disponibilidad y el precio de productos o servicios. Como habitaciones de hotel o asientos de avión.

En relación con lo definido, podría concluirse entonces que el RM tiene ciertos objetivos vitales: maximizar los ingresos totales, optimizar la ocupación, segmentar el mercado y ofrecer tarifas en función del cliente y prever la demanda.

Concretando en el ámbito hotelero. Un hotel siempre pretende vender al mayor precio posible sus habitaciones y mantener una ocupación del 100% cada noche. Este comportamiento es utópico, pues muchos factores influyen en el precio de la habitación y la ocupación del hotel. El RM propone las estrategias para maximizar en lo posible esos ingresos mientras maximiza en lo posible la ocupación.

De hecho, Silvia-Patricia et al. (2024) desarrollo en su artículo un caso de éxito real de la gestión dinámica de precios en la cadena de hoteles Marriott, y concretamente, en el hotel Courtyard by Marriott Bucharest Floreasca. En él, se evalúa cómo distintas políticas -precios fijos vs. dinámicos, descuentos por volumen, paquetes promocionales, y condiciones de cancelación flexibles- influyen en la ocupación y los ingresos hoteleros.


En concreto, los autores describen el diseño de tarifas adaptadas al tamaño del grupo, la duración de la estancia y la estacionalidad, y comparan dos enfoques principales:

- Precios fijos, empleados generalmente en contratos corporativos a largo plazo, que ofrecen predictibilidad tanto al hotel como al cliente.
- Precios dinámicos, actualizados en tiempo real según demanda, disponibilidad y comportamiento del mercado, que permiten capturar picos de alta ocupación y estimular reservas en periodos bajos

Mediante entrevistas con el personal del hotel, análisis de informes internos y *feedback* de organizadores de eventos, se documenta que la adopción de dinámicas de precios y paquetes personalizados -incluyendo descuentos progresivos para grupos más grandes y promociones de temporada- contribuyó a incrementar la facturación de diciembre de 2024 en un 13,8 % respecto a 2023 y a mantener un nivel de ocupación equilibrado entre clientes individuales y grupos.

Asimismo, la implementación de una política de cancelación flexible fortaleció la confianza del cliente, elevó las tasas de conversión y fomentó la fidelidad, sin sacrificar la rentabilidad gracias al ajuste continuo de tarifas mediante sistemas de RM. En el análisis cuantitativo, como indica la Figura 4, se observa un crecimiento sostenido de las habitaciones vendidas entre 2022 y 2024: un aumento total del 18,6 %, con un alza del 15,2 % en el segmento individual y del 39,9 % en el de grupos (pese a una ligera caída del 3,6 % en 2024 tras un pico en 2023). Estos resultados confirman que una estrategia de precios “*data-driven*” y centrada en el cliente, que combina modelos de fijación fija y dinámica, puede mejorar simultáneamente la ocupación y los ingresos en un entorno competitivo y volátil.

Figura 4. Ingresos por habitaciones del hotel Courtyard by Marriott



Fuente: Silvia-Patricia et al. (2024)

Estudios como el de Ropero (2011) también analizan cómo se fijan dinámicamente los precios de las habitaciones de hotel y apartamentos turísticos. Este caso es interesante porque se centra en España, concretamente en Islas Canarias y Baleares, utilizando como base el canal de distribución online (eDreams.com). A partir de un conjunto de datos diario de 572 establecimientos en agosto de 2005, Ropero estima -mediante modelos probit y tobit- la probabilidad de que cada hotel suba o baje sus tarifas y la magnitud de esas variaciones en función de sus características (calidad del servicio, categoría, tamaño) y de las condiciones del mercado (nivel de competencia, diferenciación de producto).

Los resultados muestran que cuanto mayor es la calidad percibida, más probable es que un hotel incremente su precio y en mayor medida, mientras que la distancia entre su tarifa y el precio medio de los competidores no influye en la probabilidad de aplicar descuentos. Esto sugiere que la diferenciación de producto -más que la presión competitiva de tarifas similares- es el principal motor de la política de precios en estos destinos.

Sin embargo, con el avance de la tecnología y la disponibilidad de grandes volúmenes de datos, ha surgido la oportunidad de aplicar técnicas más sofisticadas, que permitan modernizar las estrategias de RM, o incluso, automatizarlas, consiguiendo resultados óptimos.

Entre esas técnicas se encuentra el aprendizaje automático o *Machine Learning* (ML), que puede utilizarse para predecir los precios de las habitaciones de manera más precisa y dinámica (Moro et al., 2017). La capacidad de predecir los precios de las habitaciones permite a los hoteles optimizar sus estrategias de precios, mejorar la ocupación y maximizar los ingresos. Además, proporciona una ventaja competitiva al permitir una respuesta más ágil a las condiciones cambiantes del mercado y a las preferencias de los consumidores.

Por ello, este trabajo permite contribuir, utilizando técnicas avanzadas y modernas como ML, a la solución del problema que plantea la gestión de ingresos de un establecimiento hotelero. No solo consiguiendo una buena precisión en el ajuste de los precios de las habitaciones, sino también automatizando estos procesos para simplificar la tarea del gestor.

2.2.Estado del arte

Tras entender el contexto del problema, en este apartado se repasan diversas publicaciones previas en el ámbito de este trabajo o similar, que puedan ayudar al desarrollo de este. Esto es importante para comprender el camino que ya hay recorrido, evitar líneas de investigación sin éxito demostrado, y utilizar la información existente para enriquecer la aquí descrita.

Este apartado se divide en diversas subsecciones que irán recorriendo diferentes conceptos que serán útiles a lo largo de este proyecto.

En primer lugar, en la sección 2.2.1, se examinan los fundamentos teóricos de los modelos hedónicos de precios, partiendo de la idea de que el valor de un bien o servicio se descompone en el aporte individual de sus atributos.

Tras ello, en la sección 2.2.2 se presenta cómo, más allá de los modelos hedónicos tradicionales que valoran atributos estáticos del hotel, las técnicas de ML y de series temporales permiten capturar dinámicamente la evolución de las tarifas en función de factores cambiantes (estacionalidad, eventos, demanda, variables exógenas) para lograr una fijación de precios más precisa y adaptativa.

Por último, la sección 2.2.3 se centra en identificar los principales factores que determinan el precio de una habitación. Se describen atributos estáticos del establecimiento (categoría, tamaño, servicios y políticas de cancelación), variables geográficas (proximidad a puntos de interés y transporte) y dinámicas de mercado (estacionalidad, reseñas en línea y estrategias de la competencia) que, de forma recurrente, han demostrado influir de manera significativa en los sistemas automáticos de predicción de precios. A pesar de las limitaciones en la obtención de algunos datos, se muestra cómo la integración de estos factores es esencial para alcanzar una alta precisión en el RM hotelero.

2.2.1. Modelos hedónicos

Los modelos hedónicos de precios parten de la idea de que el valor de un bien o servicio se deriva de la suma de los valores parciales de sus atributos individuales (Chau & Chin, 2003). En el ámbito hotelero, esto significa que el precio de una habitación no es un precio “único”, sino el resultado de cómo el mercado valora factores como la categoría del establecimiento (estrellas, diseño, reputación), la localización (distancia al centro urbano o a atractivos turísticos), la disponibilidad de servicios (restaurantes, spa, piscina, wifi) y características intangibles (nivel de atención, marca, experiencias asociadas).

Estos modelos se estiman habitualmente mediante regresiones lineales o no lineales en las que el precio medio por noche es la variable dependiente y los atributos del hotel, las condiciones de mercado (temporada, demanda por destino) y las características de la oferta competitiva son las variables explicativas. De este modo, es posible cuantificar, por ejemplo, cuánto paga de más un huésped por hospedarse en un establecimiento de categoría superior frente a uno de categoría media, o la prima asociada a estar frente a la playa en temporada alta.

Espinet et al. (2003) aplicaron este enfoque al mercado vacacional español, demostrando que cada estrella adicional incrementa significativamente el precio, y que la proximidad a la costa puede llegar a representar hasta un 20 % de la tarifa base. Por su parte, Coenders et al. (2001) incorporaron en sus modelos curvas de crecimiento latente para capturar variaciones estacionales, mostrando que la elasticidad del precio respecto a la categoría hotelera cambia según el momento del año y la ubicación geográfica del destino.

Agmapisarn (2014) implementó un modelo hedónico para descomponer el precio de las habitaciones en función de atributos observables de los hoteles en Bangkok, identificando que las cadenas cobran, en promedio, un 32 % más que los establecimientos independientes. Su análisis reveló además que, durante la temporada alta, los precios de fin de semana aumentan significativamente en hoteles de cadena con habitaciones más amplias y ubicados cerca del centro urbano. Independientemente de la estación, los nuevos hoteles de cadena situados en zonas céntricas y dotados de bar y restaurante suelen exigir tarifas superiores a las de cadenas más veteranas y alejadas del núcleo. Asimismo, la cercanía a estaciones de transporte público emerge como un factor clave que permite a cualquier hotel, independiente o de cadena, imponer precios notablemente más elevados que aquellos situados a mayor distancia.

Más recientemente, Giannoni et al. (2024) ampliaron el análisis clásico al incorporar variables de servicios complementarios y experiencias personalizadas (actividades guiadas, ofertas de bienestar, gastronomía local), utilizando una base de datos detallada de alojamientos en un destino costero. Sus resultados indican que la heterogeneidad de precios responde no solo a los atributos básicos, sino también a paquetes de servicios y a la percepción de calidad de la marca.

Por último, en el ámbito de los modelos hedónicos, destaca el estudio de Modjo y Widowo (2023). Los autores recopilaron un *dataset* de 194 hoteles en el área de Bogor (Indonesia) a partir de un sitio de agencia de viajes online e implementaron un modelo de regresión hedónica cuantílica para analizar cómo distintas posiciones geográficas influyen en las tarifas. Los resultados muestran que la cercanía a atracciones turísticas es un factor estadísticamente significativo que encarece las habitaciones. Además, el estudio confirma el efecto positivo de otras variables clásicas, como el tamaño de la habitación y categoría por estrellas.

En conjunto, estos estudios confirman la utilidad de los modelos hedónicos para desentrañar la contribución de cada característica al precio final, y ofrecen a los gestores hoteleros y a los planificadores turísticos herramientas cuantitativas para diseñar estrategias de precios más ajustadas a la demanda y a la competencia. Estas conclusiones obtenidas sobre qué variables influyen o no en el precio suponen un buen punto de partida a la hora de confeccionar el *dataset* que se utilizará para el desarrollo del trabajo.

2.2.2. Aprendizaje automático y análisis de series temporales

Como complemento a los modelos hedónicos, que explicitan el efecto de cada atributo sobre el precio de la habitación, los enfoques basados en ML y series temporales aportan una visión dinámica y no lineal de la formación de tarifas. Mientras los modelos hedónicos ofrecen estimaciones puntuales de la prima asociada a características estáticas (categoría, ubicación, servicios), los algoritmos de ML y las técnicas de series temporales permiten captar cómo varían esos precios en el tiempo y en función de condiciones cambiantes (estacionalidad, eventos, demanda competitiva). De este modo, la integración de ambos marcos teóricos -la descomposición hedónica de atributos y la predicción temporal de patrones complejos- facilita un sistema de fijación de precios que, por un lado, valora correctamente las cualidades del hotel y, por otro, ajusta dinámicamente las tarifas a la evolución real de la demanda y las circunstancias del mercado.

En ese aspecto, los enfoques de predicción de precios hoteleros han transitado desde los modelos clásicos de series temporales -como SARIMA (Dommelen, 2021), que capturan patrones estacionales y tendencias lineales- hacia arquitecturas de aprendizaje automático capaces de modelar relaciones no lineales y dependencias complejas en los datos. En los primeros trabajos, los modelos autoregresivos integrados (ARIMA) y sus extensiones estacionales se empleaban para anticipar la demanda y ajustar tarifas según ciclos anuales o mensuales (Pérez Triana et al., 2025). La Figura 5 explica de forma gráfica la diferencia entre los modelos ARIMA y SARIMA.

Figura 5. Entendimiento modelos SARIMA y ARIMA.

What are ARIMA and SARIMA Models?




ARIMA combines AutoRegression (AR), Differencing (I), and Moving Average (MA). SARIMA extends this by incorporating a Seasonal component, making it suitable for datasets with periodic patterns.

Fuente: Siguiendo [enlace](#).

Aunque no está enfocado en la predicción de precios concretamente, el trabajo de Zheng et al. (2024) emplea series temporales de demanda diaria de hoteles, junto con atributos espaciales (por ejemplo, proximidad y agregación de establecimientos vecinos) y características temporales a varias escalas (diaria, semanal y mensual) para predecir la demanda de los hoteles. De este modo, el modelo incorpora información histórica de ocupación y de contexto geográfico para enriquecer las predicciones. En él se presenta un nuevo modelo de pronóstico, denominado MS-STF (*Multi-Scale SpatioTemporal Forecasting*, diseñado para capturar de forma dinámica características tanto espaciales como temporales a distintas escalas, con el fin de mejorar la exactitud en la predicción de la demanda hotelera. La Figura 6 define de forma gráfica el funcionamiento y la estructura de modelo MS-STF utilizado en el artículo.

Figura 6. Estructura modelo MS-STF.



Fuente: Zheng et al. (2024)

Sin embargo, estas técnicas adolecen de rigidez cuando los patrones de precio dependen de múltiples factores externos. Los modelos clásicos de series temporales, como ARIMA o SARIMA, se fundamentan en la idea de que la evolución futura de una variable depende únicamente de sus valores pasados y de patrones regulares de tendencia o estacionalidad.

Esta visión resulta demasiado restrictiva cuando los precios hoteleros están influidos por fenómenos externos, como promociones puntuales, festivales locales, campañas de la competencia o cambios repentinos en la demanda, que no siguen ciclos predecibles. En contraste, los algoritmos de ML y las redes neuronales pueden incorporar directamente esas variables exógenas (fechas de eventos, índices de competencia, indicadores de marketing), aprender relaciones complejas y no lineales entre ellas y el precio, y adaptarse dinámicamente a nuevas circunstancias sin necesidad de reformular la estructura del modelo. Gracias a esta capacidad de integrar múltiples fuentes de información y de capturar efectos interactivos entre factores internos y externos, los métodos basados en ML suelen ofrecer predicciones más precisas y robustas en entornos tan volátiles como el RM hotelero.

La incorporación de algoritmos de ML, desde regresión lineal hasta Support Vector Machines (SVM), Random Forest y Deep Neural Networks (DNN), ha permitido enriquecer las predicciones con variables de diversa naturaleza:

- Atributos del hotel (categoría, número de habitaciones, servicios complementarios).
- Señales de mercado (calificaciones en línea, puntuaciones de clientes, reseñas e índices de sentimiento).
- Datos externos (clima, eventos culturales o feriados, nivel de ocupación de la zona).

En este ámbito, Shehhi y Karathanasopoulos (2019), mostraron que los algoritmos de DL, especialmente los basados en lógica difusa adaptativa, pueden mejorar significativamente la exactitud de las previsiones de precios en el sector hotelero del Golfo de oriente medio. En ese estudio se buscó comparar la precisión y velocidad de cuatro modelos de pronóstico de precios de habitación, tanto tradicionales como basados en Inteligencia Artificial (IA), con el fin de ayudar a los gestores hoteleros a elegir la mejor herramienta para sus sistemas de RM. Demostrando, finalmente, que los basados en IA obtenían mejores resultados.

Por otra parte, el estudio de Anshori et al. (2025) compara la eficacia de dos técnicas de ML, Gradient Boosting Regression (GBR) y Support Vector Regression (SVR), en la predicción de los ingresos por habitaciones de un hotel local indonesio, con el fin de mejorar las estrategias de RM. Se termina concluyendo que tanto GBR como SVR muestran un rendimiento comparativamente excelente. Los gestores pueden integrarlos en sus sistemas para afinar la fijación de precios y la asignación de recursos.

Otro artículo (Hu & Song, 2022) plantea un modelo para comprender y simular cómo se forman los precios de las habitaciones en hoteles económicos, conocidos como *budget hotels*, integrando datos masivos *-big data-* y técnicas de ML desde una perspectiva espacial. En concreto, Hu y Song recopilan información georreferenciada de tarifas en múltiples establecimientos de una ciudad china, junto con variables de contexto como densidad de oferta hotelera, accesibilidad a transporte, puntos de interés turísticos y demográficos locales. Mediante un análisis de factores influenciadores, identifican qué atributos geográficos y de entorno -por ejemplo, proximidad al centro urbano o a estaciones de metro, concentración de competidores cercanos- ejercen mayor impacto en la formación del precio medio. A partir de ahí, desarrollan un modelo predictivo basado en algoritmos de *gradient boosting* que, entrenado con dichas variables, logra estimar con alta fidelidad la distribución espacial de las tarifas.

Finalmente, los autores validan su propuesta mediante simulaciones que reproducen escenarios de redistribución de la oferta (apertura o cierre de hoteles) y proyectan cómo variarían los precios en función de cambios en el entorno. Sus resultados demuestran que, al incorporar información detallada del espacio urbano y variables externas recogidas en tiempo real, los sistemas de RM pueden ajustar de forma más precisa sus estrategias de fijación de precios, mejorando la rentabilidad en nichos de mercado altamente competitivos y sensibles a la ubicación.

Otro estudio reciente en este ámbito es el realizado por Oliveira et al. (2024). En este trabajo, los autores combinan modelos de series temporales (autoregresores clásicos y Prophet) con diversos algoritmos de ML, como Random Forest, Gradient Boosting Machine, Extra Trees Regressor y redes neuronales, para predecir las tarifas de habitaciones de hotel. Emplean un conjunto de más de 40.000 reservas reales de un gran hotel brasileño, utilizando como variables explicativas el tiempo de antelación de la reserva, la ocupación histórica, las noches reservadas y el número de huéspedes, además de patrones estacionales extraídos del propio histórico de precios.

Los resultados muestran que los métodos basados en árboles (especialmente Gradient Boosting) obtienen el mejor rendimiento, alcanzando un error normalizado (NRMSE) del 6,94% y un MAE de 31,26 unidades monetarias. Superan de forma significativa tanto a los modelos de series temporales por sí solos como a las redes neuronales. Este enfoque híbrido

demuestra que integrar características del hotel y señales temporales con potentes regresores de ML permite estimaciones de precios más precisas, aportando una herramienta valiosa para optimizar las estrategias de RM en establecimientos hoteleros.

También es importante destacar algunos artículos publicados que utilizan técnicas de ML centrados en el turismo, a pesar de que no estén enfocados a la predicción de precios. Esto es útil para entender la magnitud de las soluciones de ML en el mundo actual y comprender que son soluciones con casos de éxito previos en más áreas relacionadas.

Viverit et al. (2023) desarrollan un método en dos pasos para predecir la tasa diaria de ocupación de un hotel. Primero, agrupan curvas de reserva usando *clustering*, y luego las integran en un modelo de “*additive pickup*”. Sobre un conjunto de datos de múltiples hoteles europeos, este enfoque reduce el error de predicción diaria de ocupación en un 15 % frente a modelos pickups clásicos.

Zhang y Niu (2024) integran reseñas y calificaciones extraídas de plataformas OTA dentro de un modelo de red neuronal profunda. Gracias a la incorporación de variables de sentimiento y texto libre, logran reducir el MAE en un 12% frente a un LSTM estándar. Esto confirma que el análisis semántico de opiniones potencia la precisión de los pronósticos de ocupación.

2.2.3. Factores que influyen en los precios

El repaso de toda la literatura relacionada con el ajuste del precio de las habitaciones de hotel utilizando ML y otras técnicas distintas consigue establecer una serie de factores como determinantes. Durante todos los estudios, una serie de atributos se erigen como constantes a la hora de llevar a cabo el proceso automático de predicción y ajuste de precios. Entre los más destacados se encuentran:

- **Características del hotel:** La categoría del hotel, el tamaño, los servicios ofrecidos (como piscina, gimnasio, Wi-Fi gratuito) y las políticas de cancelación.

Zhang et al. (2011), a través de un modelo hedónico de precios, identificaron que la calidad de la habitación y la ubicación son determinantes importantes del precio de la habitación en la industria hotelera. También, estudiaron que cada estrella adicional del hotel incrementa la tarifa en un 35,8% aproximadamente.

- **Ubicación geográfica:** La proximidad a atracciones turísticas, centros de negocios y medios de transporte.

El estudio de Zhang et al. (2011) ya mencionado destaca que la ubicación es un atributo reconocido en la industria hotelera que influye en la fijación de precios. La cercanía al centro urbano o a nodos de transporte se asocia con aumentos significativos en la tarifa.

A su vez, el estudio de Modjo y Wibowo (2023) anteriormente comentado, también sirve como referencia para tomar en cuenta la ubicación del hotel como un factor determinante a la hora de establecer las tarifas.

- **Estacionalidad:** Las variaciones en la demanda según la temporada del año, días de la semana y eventos locales.

El modelo propuesto por Zheng et al. (2024) incorpora explícitamente patrones semanales (día de la semana) y mensuales (variaciones estacionales) al segmentar la serie histórica de demanda en escalas temporales diferenciadas.

Otro estudio confeccionado con Wang et al. (2019) también analiza la influencia de la estacionalidad en los precios. En ese caso concreto, analizan el turismo en la ciudad china de Sanya. Sanya presenta un típico ciclo turístico con temporada alta que abarca desde noviembre hasta abril, cuando el clima cálido atrae a turistas de otras regiones de China, y un bajón de mayo a octubre debido al calor exacerbado. El pico máximo ocurre durante el Año Nuevo Chino. Esta dinámica queda reflejada en el número de visitantes y la tasa de ocupación hotelera a lo largo de 2017. Durante el desarrollo del estudio demuestran cuantitativamente que la estacionalidad es uno de los determinantes más potentes del precio hotelero en destinos de marcado ciclo turístico, con variaciones que oscilan entre un +23% y un +160%, según el periodo considerado.

España, a pesar de ser turística a lo largo de todo el año, está fuertemente marcada por la época de verano. O lo que es lo mismo, la influencia de la estacionalidad en los precios está igualmente presente en el mercado español.

- **Puntuaciones y reseñas en línea:** Las calificaciones de los clientes en plataformas como TripAdvisor y Booking.com, que afectan la percepción de calidad y, por ende, el precio que los clientes están dispuestos a pagar.

El estudio de Sparks y Browning (2011) analiza cómo las opiniones publicadas en línea influyen en la intención de reserva de los usuarios y en su percepción de confianza hacia un hotel. A partir de dos experimentos de laboratorio y una encuesta de campo, los autores muestran que una mayor cantidad de reseñas y unas valoraciones globales positivas incrementan significativamente la probabilidad de que un potencial cliente decida reservar. Al mismo tiempo, descubren que la credibilidad percibida de esas reseñas-medida según su detalle, coherencia y la reputación de la fuente- refuerza la confianza en el establecimiento y actúa como mediador entre la calidad de las opiniones y las intenciones de reserva.

En detalle, Sparks y Browning revelan que las reseñas positivas elevan la expectativa de satisfacción del cliente, mientras que las negativas pueden disuadirlo más allá de lo que justificaría el propio contenido crítico, especialmente si las valoraciones provienen de usuarios calificables como “expertos” o “confiables”. Los autores concluyen que gestionar activamente la presencia en plataformas de reseñas y fomentar *feedback* de alta calidad resulta clave para fortalecer la confianza del cliente y, en última instancia, mejorar las tasas de conversión en reservas. Esto implica, de forma casi directa, un aumento del precio de medio al que se vende la habitación, puesto que una mayor cantidad de reserva supone una mayor demanda. Al aumentar la demanda, pero no pudiendo aumentar la oferta de habitaciones, el precio de la habitación debe aumentarse, equilibrando ambos factores.

Otro estudio relevante que demuestra la importancia de las valoraciones online del hotel es el de Diana-Jens y Ruibal (2015). Analiza cómo la reputación online -entendida como el conjunto de valoraciones y reseñas de huéspedes en plataformas como TripAdvisor- influye directamente en la política de precios de los hoteles. Empleando datos de más de 200 establecimientos y su posición en el *Popularity Index* de TripAdvisor, los autores muestran que los hoteles con mejores puntuaciones pueden aplicar, en promedio, hasta un 12 % más de tarifa sin afectar negativamente su ocupación, evidenciando que las altas calificaciones no solo mejoran la confianza del consumidor, sino que también incrementan el poder de fijación de precios de los establecimientos.

- **Competencia:** Los precios y estrategias de hoteles competidores en la misma área geográfica.

Zhang et al. (2011) encontraron que las condiciones del mercado son determinantes significativos en la categoría de precios altos, y que la proporción de viajeros individuales extranjeros influye positiva y significativamente en el precio de la habitación.

El análisis de estos factores mediante técnicas avanzadas permite a los hoteles ajustar sus precios de manera más precisa y responder de forma proactiva a las condiciones del mercado. En este trabajo, se han tenido en cuenta estos factores. Sin embargo, hay algunos de ellos sobre los que no se ha podido obtener información. Aun así, se pretende obtener una gran precisión.

2.2.4. Trabajos que aplican técnicas de ML y redes neuronales en otros ámbitos

A continuación, a pesar de que ya se ha llevado a cabo un exhaustivo análisis del estado del arte en el ámbito de este trabajo, este apartado se centra en ejemplos concretos que demuestran la eficacia real de las técnicas seleccionadas en la parte práctica del TFM. Este repaso de casos de éxito tiene dos objetivos principales: por un lado, ilustrar cómo cada método ha resuelto problemas reales en distintos contextos y, por otro, aportar evidencias prácticas que justifiquen su aplicación en el presente estudio.

En primer lugar, se presentan ejemplos donde la regresión lineal ha permitido modelar tendencias y relaciones en datos con alta interpretabilidad y simplicidad. A continuación, se analizan proyectos en los que la regresión Ridge ha mejorado la estabilidad de los coeficientes ante multicolinealidad, garantizando predicciones más robustas. Seguidamente, se muestran aplicaciones de Random Forest que han aprovechado su capacidad de manejo de variables categóricas y su resistencia al sobreajuste. Más adelante, se revisan casos de XGBoost, cuyos potentes algoritmos de *boosting* han alcanzado éxitos destacados en competiciones y entornos de producción. Finalmente, se cierra con aplicaciones de redes neuronales, donde su flexibilidad y escalabilidad han permitido abordar problemas de alta complejidad, como el reconocimiento de imágenes o el procesamiento de lenguaje natural.

Este recorrido no solo sirve para conocer los alcances de cada técnica, sino también para extraer lecciones clave sobre su implementación práctica, los retos superados y las métricas de éxito obtenidas. De este modo, se tendrá una base sólida para justificar la elección de las metodologías aplicadas.

En un estudio reciente publicado como *preprint* en Research Square el 3 de julio de 2024, Phan et al., muestran cómo un modelo de regresión lineal puede servir de base para prever con fiabilidad el consumo energético en entornos reales. Los autores aplican el modelo a tres escenarios muy distintos: el consumo diario de un supermercado en Reino Unido, los patrones de demanda de la red insular de Puerto Princesa (Filipinas) y datos de consumo captados por dispositivos IoT. Comparan la versión “pura” de la regresión lineal con una variante mejorada que incorpora ajustes en la selección de variables y el tratamiento de ruido. Los resultados revelan que ambas aproximaciones alcanzan altos niveles de precisión, con mejoras claras en la planificación y gestión de recursos energéticos gracias a la simplicidad y la interpretabilidad del modelo lineal.

Por otro lado, Lu (2025) explora el uso de regresión Ridge dentro del marco del modelo media-varianza para la optimización de carteras financieras. Los autores aplicaron Ridge regression y Random Forest sobre datos históricos de acciones comprendidos entre julio de 2014 y julio de 2023, incorporando indicadores técnicos como medias móviles (MA50, MA200), volatilidad y métricas basadas en volumen. Gracias al término de penalización de Ridge, el modelo consiguió reducir la varianza de las estimaciones de los coeficientes sin sacrificar significativamente el sesgo, lo que se tradujo en una mejora notable de los retornos ajustados al riesgo en comparación con las aproximaciones clásicas.

Nava-Yazdani (2024) extiende la regresión Ridge a espacios relevantes para series temporales sobre variedades diferenciales. Empleando ajustes intrínsecos basados en teoría de Riemann, desarrollan una versión de Ridge que opera directamente sobre datos de trayectoria de huracanes, utilizando una métrica de Mahalanobis adaptada a la geometría de la variedad. Los experimentos muestran que este enfoque no solo mantiene la robustez frente a ruido y multicolinealidad, sino que también mejora la precisión en la predicción de la posición y la velocidad del viento de tormentas tropicales, ofreciendo una herramienta prometedora para la meteorología operativa.

Taye et al. (2025) emplean Random Forest complementado con explicaciones SHAP para predecir la asistencia de personal cualificado al parto entre mujeres en edad reproductiva en 27 países del África Subsahariana. Con datos procedentes de las Encuestas de Demografía y Salud (2016-2024) que abarcaron más de 198.000 encuestas, el modelo integró técnicas de imputación de valores faltantes (KNN), balanceo de clases (SMOTE) y selección de


características (RFE), logrando una robusta capacidad predictiva. Este enfoque no solo identificó con precisión los determinantes clave de la asistencia al parto, como nivel educativo, acceso a centros de salud y características socioeconómicas, sino que también proporcionó información accionable para diseñar políticas de salud pública más efectivas.

Rouhani & Farrokh (2025), en un trabajo de investigación aplicado a la ingeniería de túneles, presenta un enfoque híbrido que integra algoritmos metaheurísticos con XGBoost para predecir la penetración por revolución (Prev) de máquinas tuneladoras TBM en el proyecto del túnel Ghomroud. Seleccionando características geotécnicas clave (UCS, RMR) y parámetros operativos de la máquina (Fn, Fr), el estudio desarrolló tres modelos empíricos basados en XGBoost que alcanzaron valores de R^2 entre 0,67 y 0,70. Este avance ha permitido afinar la planificación de avance de obra y reducir costes operativos al anticipar con mayor precisión el rendimiento de las TBM en condiciones geológicas variables.

En el artículo de Abiodun et al. (2018), los autores revisan más de 200 trabajos para ofrecer una taxonomía comprensiva de arquitecturas de redes neuronales (*feedforward*, *feedback* y variantes profundas) y mapear su aplicación en más de quince disciplinas, desde la ingeniería y la medicina hasta la agricultura, la energía y las finanzas; analizan el desempeño de los modelos según criterios como precisión, velocidad de procesamiento, tolerancia a fallos y escalabilidad. Destacan casos donde las redes neuronales han superado a métodos estadísticos clásicos en tareas reales. Además, discuten los retos principales como volúmenes masivos de datos etiquetados, interpretabilidad y coste computacional, y proponen como vía futura el desarrollo de enfoques híbridos y redes multi-modelo que combinen distintas arquitecturas para maximizar tanto la eficacia como la eficiencia en aplicaciones del mundo real. A su vez, hacen una clasificación de los diferentes tipos de redes neuronales existentes, mostrados en la Figura 7. Este “survey” sirve de base para entender el gran alcance que tienen las redes neuronales.

Con estos artículos de ejemplo se puede observar la relevancia que poseen hoy en día estas técnicas. A continuación, se van a desarrollar las conclusiones extraídas durante el desarrollo de este capítulo.

Figura 7. *Clasificación de las redes neuronales según Abiodun et al. (2018)*



Fuente: Abiodun et al. (2018)

2.3.Conclusiones

En este capítulo se ha revisado de manera integral el contexto y las principales aportaciones teóricas y empíricas relacionadas con la fijación dinámica de precios en la industria hotelera. En primer lugar, se ha situado el análisis en el marco de la gestión de ingresos o RM, subrayando su origen en el sector aéreo (Kosten, 1960; Littlewood, 1972) y su evolución hasta su adopción en el mundo de la hotelería contemporánea (Ivanov & Zhechev, 2012). Se ha destacado la naturaleza multidimensional del precio de las habitaciones, que no solo refleja los costos operativos, sino también atributos del establecimiento, características del mercado y factores externos como la estacionalidad y las reseñas en línea (Sánchez-Pérez et al., 2019; Abrate et al., 2011).

A continuación, la sección dedicada al estado del arte ha mostrado que los modelos hedónicos constituyen una sólida base para descomponer el precio en función de atributos específicos (Chau & Chin, 2003). Estudios pioneros en España (Espinete et al., 2003) y en contextos internacionales como Bangkok (Agmapisarn, 2014) o Bogor (Modjo & Widowo, 2023) han demostrado cómo variables como la categoría del hotel, la ubicación y los servicios complementarios influyen significativamente en las tarifas.

Sin embargo, la rigidez de los modelos clásicos de series temporales, como ARIMA o SARIMA (Dommelen, 2021), a la hora de integrar variables exógenas ha impulsado la adopción de técnicas de ML. La incorporación de algoritmos de ML (por ejemplo, SVM, Random Forest, Gradient Boosting) y de arquitecturas neuronales ha permitido capturar relaciones no lineales entre atributos del hotel, señales de mercado (reseñas online, sentimiento) y factores externos (clima, eventos) (Moro et al., 2017; Zheng et al., 2024).

Trabajos recientes demuestran el valor de enfoques híbridos: Oliveira et al. (2024) obtuvieron un NRMSE del 6,94% combinando Prophet con regresores de árbol; Anshori et al. (2025) compararon con éxito Gradient Boosting y SVR en Indonesia; y Shehhi & Karathanasopoulos (2019) evidenciaron las ventajas de la lógica difusa adaptativa en el Golfo Pérsico.

El repaso de la literatura también ha identificado los factores determinantes de la fijación de precios hoteleros:

- Atributos del establecimiento (categoría, tamaño, servicios y políticas de cancelación) (Zhang et al., 2011).
- Ubicación geográfica y proximidad a atractivos o transporte público (Modjo & Widowo, 2023).
- Estacionalidad y ciclos turísticos (Wang et al., 2019; Zheng et al., 2024).
- Puntuaciones y reseñas online, que determinan la percepción de calidad y la disposición a pagar (Sparks & Browning, 2011; Diana-Jens & Ruibal, 2015).
- Estrategias de la competencia.

Los casos de éxito analizados, como el estudio de la cadena Marriott en Bucarest (Silvia-Patricia et al., 2024), demuestran la factibilidad y rentabilidad de políticas de precios dinámicos que condujeron a un incremento del 13,8% en ingresos en diciembre de 2024 y a un mayor equilibrio en la ocupación. Estos resultados confirman que un enfoque *data-driven*, que combina modelos hedónicos y aprendizaje automático, mejora simultáneamente la ocupación y los ingresos en entornos volátiles.

En definitiva, el uso de modelos hedónicos, series temporales y métodos de ML proporciona un punto de partida robusto para desarrollar un sistema automatizado de fijación de precios. A partir de la identificación de los factores clave y de los modelos más eficaces, este trabajo se orienta a construir un modelo predictivo que permita tanto cuantificar la contribución de cada atributo al precio como ajustar dinámicamente las tarifas en función de la evolución real de la demanda. La integración de estas metodologías avanzadas no solo promete mejorar la precisión de las predicciones, sino también simplificar la tarea del gestor, consolidando un sistema de RM eficiente y adaptable al entorno competitivo del sector hotelero.

A continuación, en el Capítulo 3, se definen los objetivos concretos que guían este trabajo, así como la metodología adoptada para su consecución. Se parte de una visión global del

problema para luego desglosar una serie de metas específicas que estructuran el desarrollo del análisis, abarcando desde la exploración inicial de los datos hasta la evaluación comparativa de modelos predictivos y la generación de visualizaciones interpretables.

3. Objetivos concretos y metodología de trabajo

Este apartado tiene como finalidad exponer los objetivos que guían el presente trabajo, así como detallar las metas específicas que se pretenden alcanzar. Del mismo modo, se describe la metodología adoptada para cumplir con dichos objetivos, combinando enfoques analíticos, técnicos y visuales en el tratamiento del conjunto de datos.

3.1. Objetivo general

Los proyectos de análisis de datos aplicados no deben limitarse a la creación de herramientas o metodologías, sino que deben aspirar a generar un impacto real y medible. El propósito es demostrar cómo el análisis de datos puede conducir a interpretaciones relevantes, con resultados observables que faciliten la toma de decisiones en contextos reales.

El objetivo principal del trabajo es desarrollar y aplicar un modelo analítico avanzado que permita predecir y comprender las variables que influyen en el precio de los hoteles. Para ello, se plantea un enfoque integral que incluye la limpieza, normalización y análisis exploratorio de un conjunto de datos de gran volumen, así como la implementación y comparación de diferentes modelos predictivos basados en bibliotecas como Scikit-learn, TensorFlow o Xgboost.

A su vez, se integran herramientas de visualización como `matplotlib` y `seaborn` para representar gráficamente la distribución de variables (mediante histogramas, diagramas de caja, etc.) y analizar su correlación. El sistema resultante no solo permitirá realizar análisis de forma eficiente, sino que también proporcionará visualizaciones claras y métricas de rendimiento que faciliten la comparación entre modelos.

La combinación de análisis estadístico, aprendizaje automático y visualización busca construir una solución robusta, segura y fundamentada en datos que aporte valor añadido a los procesos de evaluación y fijación de precios en el sector hotelero.

En el siguiente apartado, se describen los objetivos específicos que estructuran el desarrollo del trabajo.

3.2.Objetivos específicos

A partir del objetivo general planteado, se definen a continuación una serie de objetivos específicos que permiten estructurar y guiar el desarrollo del trabajo. Cada uno de ellos representa una etapa concreta dentro del proceso analítico, contribuyendo de forma progresiva a la consecución del propósito global.

- **OE1:** Analizar la problemática existente en torno a los factores que pueden influir en el precio de los alojamientos turísticos, identificando las variables más relevantes para el estudio.
- **OE2:** Revisar los trabajos y estudios previos relacionados con la predicción de precios en el sector turístico, con el fin de establecer un marco de referencia sólido.
- **OE3:** Definir los objetivos generales y específicos del análisis, delimitando el alcance del estudio y los criterios principales que guiarán su desarrollo.
- **OE4:** Obtener, depurar y estructurar el conjunto de datos necesario para garantizar la calidad y consistencia de la información utilizada en el análisis.
- **OE5:** Desarrollar modelos que permitan examinar y predecir la relación entre las variables identificadas y el precio de los alojamientos, asegurando su coherencia con el propósito del trabajo.
- **OE6:** Analizar e interpretar los resultados obtenidos, evaluando su significado en relación con el problema planteado y contrastándolos con las expectativas iniciales.
- **OE7:** Elaborar conclusiones que integren los hallazgos más significativos y aporten recomendaciones útiles para la toma de decisiones en el contexto del estudio.

3.3.Metodología del trabajo

El desarrollo de este trabajo se articula en una secuencia metodológica sustentada en los principios del análisis de datos moderno, combinando enfoques estadísticos, modelos de aprendizaje automático y herramientas de visualización. Esta metodología no solo describe las fases del proceso, sino que justifica la selección de métodos y expone los criterios que motivaron la exclusión de otras técnicas.

En una primera etapa, se llevó a cabo la exploración inicial del conjunto de datos con el propósito de comprender su estructura y evaluar su calidad. Esta fase incluyó la identificación del número y tipo de variables, la detección de valores atípicos o ausentes y la verificación de duplicados, lo que permitió anticipar posibles problemas en etapas posteriores y definir estrategias de limpieza adecuadas.

Posteriormente, se realizó el preprocesamiento y la preparación de datos, asegurando la coherencia y la correcta interpretación por parte de los algoritmos. Este proceso contempló la imputación o eliminación de valores faltantes, la transformación de variables categóricas en numéricas y la normalización o estandarización de escalas, especialmente relevante para modelos sensibles a la magnitud de las variables. Estas operaciones resultaron indispensables para garantizar la calidad del *dataset* y su adecuada integración en fases posteriores.

Con los datos preparados, se desarrolló un análisis exploratorio que permitió describir la distribución de las variables y sus relaciones, apoyándose en representaciones gráficas que facilitaron la identificación de patrones, correlaciones y posibles problemas de colinealidad, particularmente entre variables como reputación, limpieza, confort y servicios. Asimismo, se examinó el efecto de la ubicación geográfica sobre el precio, considerando la interacción con otros factores.

En la fase analítica, se estableció un enfoque progresivo en la elección de modelos. Inicialmente, se recurrió a modelos estadísticos clásicos, como la regresión lineal simple y polinómica, que proporcionaron un marco interpretativo robusto y facilitaron la comprensión de las relaciones básicas entre variables. La regresión logística, en cambio, fue descartada por la naturaleza continua de la variable objetivo. Posteriormente, se implementaron modelos multivariantes y regularizados, como Ridge, que permiten incorporar múltiples variables y controlar el sobreajuste. El modelo Lasso, si bien útil para la selección automática de variables, no aportaba un valor diferencial significativo en este contexto, motivo por el que no se incluyó.

En una etapa más avanzada, se incorporaron algoritmos de aprendizaje automático supervisado, como Random Forest y Gradient Boosting (XGBoost), cuya capacidad para manejar relaciones no lineales y reducir la varianza los hace especialmente adecuados para este tipo de problema. Métodos como Support Vector Regression fueron descartados debido a su elevado coste computacional en conjuntos de datos de tamaño medio y a su menor interpretabilidad. Asimismo, se implementaron redes neuronales artificiales por su potencial

para modelar interacciones complejas, descartando arquitecturas más sofisticadas como las redes convolucionales, que resultan ineficientes en datos tabulares.

El ajuste de los modelos incluyó la optimización de hiperparámetros clave mediante estrategias sistemáticas como la búsqueda en rejilla y la búsqueda aleatoria. En el caso de los modelos basados en árboles, se ajustaron parámetros como el número de estimadores, la profundidad máxima y la fracción de características consideradas en cada división. Para redes neuronales, se probaron distintas configuraciones en cuanto a número de capas y neuronas, incorporando mecanismos de regularización como *dropout* y técnicas de parada temprana para evitar el sobreajuste.

Finalmente, la evaluación del rendimiento se realizó mediante métricas estandarizadas, tales como el error absoluto medio (*MAE*), el error cuadrático medio (*MSE*), la raíz del error cuadrático medio (*RMSE*), el coeficiente de determinación (R^2) y la varianza explicada, complementadas con validación cruzada para garantizar la robustez de los resultados. Los hallazgos se presentaron a través de gráficos que permiten comparar predicciones y valores reales, así como la importancia relativa de las variables en los modelos más efectivos, lo que facilita una interpretación clara y fundamentada de los resultados.

La metodología adoptada ha permitido establecer un proceso estructurado y coherente para abordar el objetivo del estudio, desde la preparación y análisis del conjunto de datos hasta la construcción y evaluación de modelos predictivos. La combinación de técnicas estadísticas y algoritmos de aprendizaje automático, junto con la justificación en la elección de métodos y el ajuste riguroso de parámetros, ha proporcionado una base sólida para garantizar la fiabilidad de los resultados obtenidos.

En el siguiente apartado, se expone el marco normativo y los criterios de protección de datos que rigen el uso de la información empleada en el presente trabajo, asegurando el cumplimiento de las directrices legales aplicables.

4. Marco normativo

La utilización de datos en proyectos académicos y de investigación requiere garantizar el cumplimiento de las normativas vigentes en materia de privacidad y protección de la información. Aunque el análisis desarrollado en este Trabajo Fin de Máster no implica el tratamiento de datos personales de personas físicas, resulta esencial exponer las consideraciones legales aplicables, el origen de la información empleada y las medidas adoptadas para asegurar un uso responsable. En este sentido, el presente apartado describe el marco normativo de referencia, las razones por las que no resulta aplicable el Reglamento General de Protección de Datos (RGPD) ni la Ley Orgánica 3/2018 (LOPDGDD), así como las prácticas implementadas para preservar la confidencialidad y evitar riesgos asociados al tratamiento de datos vinculados a entidades jurídicas.

En el desarrollo del presente Trabajo Fin de Máster (TFM) no se han tratado datos personales de personas físicas. El conjunto de datos utilizado contiene información sobre distintos establecimientos hoteleros, incluyendo el nombre del hotel, su ubicación y diversas variables asociadas a su reputación y servicios, todas ellas referidas a personas jurídicas. Por tanto, estos datos no están sujetos a la aplicación del Reglamento General de Protección de Datos (RGPD) ni de la Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD).

Los datos fueron cedidos por una empresa colaboradora a través de uno de sus empleados, que también participa en el desarrollo del TFM. Aunque se han tenido en cuenta algunas sugerencias de dicha entidad, las decisiones sobre el análisis, tratamiento y finalidad de uso de los datos han sido adoptadas por el equipo académico responsable del trabajo, por lo que se considera que el grupo actúa como responsable del tratamiento desde una perspectiva técnica.

A pesar de no tratarse de datos personales, se ha aplicado un enfoque responsable en su manejo, garantizando la confidencialidad, la no divulgación de información sensible para los intereses comerciales de los establecimientos y la protección frente a accesos no autorizados, mediante el uso de almacenamiento seguro y controlado.

En síntesis, aunque el presente trabajo no involucra el tratamiento de datos personales y, por tanto, no se encuentra sujeto de forma estricta al RGPD ni a la LOPDGDD, se han aplicado principios de responsabilidad y confidencialidad en la gestión del conjunto de datos, garantizando un uso seguro y orientado exclusivamente a fines académicos. Establecido este marco legal y ético, el siguiente apartado se centra en el desarrollo específico de la contribución, detallando las acciones y resultados obtenidos a lo largo del proceso analítico.

5. Desarrollo específico de la contribución

En este capítulo se presenta el núcleo técnico y práctico del Trabajo de Fin de Máster, centrado en el análisis detallado de los datos, el desarrollo de modelos predictivos y la evaluación de resultados. Tras haber definido el problema, contextualizado el marco teórico y establecido los objetivos y metodología, este apartado recoge todas las acciones implementadas para abordar la predicción del precio de alojamientos turísticos en España a partir de datos obtenidos en plataformas digitales.

El capítulo se organiza en dos bloques principales. En primer lugar, se lleva a cabo una exploración exhaustiva del conjunto de datos disponible, incluyendo tareas de limpieza, análisis estadístico, tratamiento de valores atípicos y visualización. Esta fase permite identificar patrones clave y preparar el *dataset* para el modelado. En segundo lugar, se desarrollan distintos modelos predictivos que permiten estimar el precio de los alojamientos en función de variables estructurales, de valoración y de ubicación. Se comparan modelos tradicionales (como la regresión lineal), técnicas de machine learning (Random Forest, XGBoost) y redes neuronales profundas, con el fin de identificar cuál ofrece el mejor rendimiento.

La finalidad de este capítulo es demostrar la capacidad analítica y técnica del trabajo, así como justificar las decisiones adoptadas en función de los resultados obtenidos. Se busca, además, proporcionar evidencias sólidas que sustenten las conclusiones que se expondrán en el capítulo final.

5.1. Exploración y Análisis de Datos

El análisis preliminar del conjunto de datos constituye una fase fundamental para comprender su estructura, evaluar su calidad y detectar posibles inconsistencias que puedan comprometer la validez de los resultados. Esta etapa permite identificar las características principales de las variables, sus distribuciones y relaciones, así como la presencia de valores atípicos o faltantes que requieran un tratamiento específico. Asimismo, el análisis exploratorio proporciona una base sólida para la selección de técnicas y modelos en etapas posteriores, asegurando que las decisiones adoptadas se fundamenten en evidencias empíricas derivadas del comportamiento real de los datos.


5.1.1. Carga de datos y limpieza inicial

El conjunto de datos empleado en este trabajo procede de un archivo en formato `.csv`, que contiene información relativa a establecimientos hoteleros distribuidos por diversas regiones españolas. La carga se ha realizado mediante la librería `pandas`, empleando el separador “;” dado que los campos están delimitados por punto y coma.

Durante la carga se emitió un `DtypeWarning`, lo que indica que al menos una de las columnas (en este caso las posiciones 3 y 12) contenía datos de tipo mixto. Esto sugiere que en esas columnas coexisten valores numéricos y cadenas, lo cual puede deberse a formatos heterogéneos. A lo largo del proceso de limpieza se abordará esta cuestión, forzando la conversión de dichas columnas a los tipos adecuados.

A continuación, se procede a una primera visualización del contenido que permite confirmar que el archivo se ha leído correctamente y que la estructura del `DataFrame` incluye las columnas esperadas, como `id`, `nombre`, `tipo`, `categoría`, `municipio`, `provincia`, `latitud`, `longitud`, `precio`, entre otras. En total, se cuenta con 29 columnas y 1.139.557 registros. Como prueba, se puede ver en la Figura 8 con información de la salida de Jupyter.

Figura 8. *Número de registros en el dataset usado*



```
Información general del DataFrame:  
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 1139557 entries, 0 to 1139556
```

Fuente: elaboración propia

Al tratarse de datos obtenidos en contexto hispano, es habitual encontrar el uso de la coma “,” como separador decimal y el punto “.” como separador de miles, lo cual difiere del formato anglosajón que espera Python. Esto afecta especialmente a las variables numéricas como `precio`, `latitud`, `longitud`, y diversas puntuaciones como `limpieza`, `wifi_gratis` o `relación_calidad_precio`. Para estandarizar estos valores, se procede a eliminar los separadores de miles, sustituir las comas por puntos y eliminar símbolos como el euro (€), en el caso del `precio`

Esta misma lógica se aplica al resto de columnas afectadas, garantizando así la correcta interpretación numérica de los valores. En todos los casos se utiliza `errors= 'coerce'` para convertir entradas inválidas en *NaN*, lo que facilita su posterior tratamiento.

Las columnas convertidas en este proceso incluyen; `precio`, `latitud`, `longitud`, `limpieza`, `personal`, `instalaciones_y_servicios`, `confort`, `relacion_calidad_precio`, `wifi_gratis`, `ubicacion.1`.

Además, existen otras columnas que requieren de un tratamiento adicional para garantizar su consistencia tipológica. Por ejemplo, las variables `numero_reviews`, `codigo_postal` y `unidades_alojativas` se convierten al tipo `Int64` (nullable integer) para poder gestionar registros nulos sin perder la integridad del tipo entero. Además, se convierten las fechas `fecha_lectura` y `fecha_check_in` a objetos `datetime`, permitiendo realizar cálculos temporales como la anticipación de reserva (`antelacion`), que se define como el número de días entre ambas fechas.

En algunas columnas categóricas se observan valores redundantes expresados con distintas grafías o idiomas. Un ejemplo claro se encuentra en la variable `tipo_cancelacion`, donde los términos “`free_cancellation`”, “`GRATIS`”, “`non_refundable`” y “`NO_REEMBOLSABLE`” representan las mismas opciones. Para facilitar su análisis, se normalizan mediante un diccionario de mapeo.

También se elimina un subconjunto de registros correspondientes a *aparthoteles*, con el fin de centrarse exclusivamente en los hoteles, que constituyen el núcleo del análisis.

5.1.2. Análisis de estructura y calidad del conjunto de datos

Una vez realizada la limpieza inicial, se procede a revisar el tipo de dato de cada columna del *DataFrame*. Esta verificación permite comprobar que las transformaciones previas han sido efectivas, y que cada columna está correctamente tipada para su posterior análisis o modelado. Los tipos de datos observados son los siguientes:

- **Variables numéricas continuas:** `precio`, `latitud`, `longitud`, `limpieza`, `personal`, `instalaciones_y_servicios`, `confort`, `relacion_calidad_precio`, `wifi_gratis`, `ubicacion.1`, `area`, `antelacion`.

- **Variables numéricas discretas:** numero_reviews, unidades_alojativas, codigo_postal, reputacion, id.
- **Variables categóricas nominales:** nombre, tipo, categoria, municipio, provincia, region, tipo_cancelacion, ubicacion, mercado.
- **Variables temporales:** fecha_lectura, fecha_check_in.
- **Variables calculadas:** antelacion, calculada como diferencia entre las fechas de lectura y, de entrada, de tipo entero.

En la Figura 9 se muestra la salida obtenida en *Jupyter Notebook*, donde se visualiza la información de las variables que componen el *dataset*.

Figura 9. Imagen de las variables usadas del dataset

#	Column	Non-Null Count	Dtype
0	id	1139557 non-null	int64
1	nombre	1139557 non-null	object
2	tipo	1139557 non-null	object
3	categoria	1139557 non-null	object
4	codigo_postal	1129843 non-null	Int64
5	municipio	1139557 non-null	object
6	provincia	1139557 non-null	object
7	region	1139557 non-null	object
8	latitud	1122143 non-null	float64
9	longitud	1122143 non-null	float64
10	unidades_alojativas	1136549 non-null	Int64
11	ubicacion	1134384 non-null	object
12	mercado	44183 non-null	object
13	fecha	1139557 non-null	object
14	reputacion	1139557 non-null	int64
15	limpieza	1085276 non-null	float64
16	personal	1085276 non-null	float64
17	instalaciones_y_servicios	1085276 non-null	float64
18	confort	1085276 non-null	float64
19	relacion_calidad_precio	1085276 non-null	float64
20	ubicacion.1	1085276 non-null	float64
21	wifi_gratis	1071482 non-null	float64
22	numero_reviews	1138999 non-null	Int64
23	fecha_lectura	1139557 non-null	datetime64[ns]
24	fecha_check_in	1139557 non-null	datetime64[ns]
25	precio	1139557 non-null	float64
26	area	1118351 non-null	float64
27	tipo_cancelacion	1139557 non-null	object
28	antelacion	1139557 non-null	int64

Fuente: elaboración propia

El conjunto de datos objeto de estudio contiene información detallada sobre establecimientos hoteleros localizados en diversas regiones de España. Cada observación representa una

combinación única de hotel y fecha de consulta, lo cual permite analizar variaciones temporales y espaciales en el comportamiento de precios y valoraciones. A continuación, se describen las variables más relevantes del *dataset*, agrupadas por temática para facilitar su comprensión.

5.1.2.1. *Identificación y localización*

Las siguientes variables permiten identificar el establecimiento y ubicarlo geográficamente:

- **id**: identificador numérico asignado al hotel. Puede aparecer repetido en distintos registros si hay varias observaciones por fechas o condiciones diferentes.
- **nombre**: denominación comercial del establecimiento hotelero.
- **tipo**: clasificación general del alojamiento. En este estudio se han considerado únicamente los registros correspondientes a “Hotel”, excluyendo los “Aparthotel”.
- **categoría**: número de estrellas del hotel, que refleja su nivel de servicios según criterios oficiales.
- **código_postal**: código postal asignado al establecimiento, útil como proxy geográfico adicional.
- **municipio, provincia y región**: niveles administrativos de localización que permiten realizar análisis agregados por ámbito territorial. En particular, la variable *región* corresponde a la comunidad autónoma, y será clave para los análisis posteriores por zonas turísticas.
- **latitud y longitud**: coordenadas geográficas del hotel. Estas variables son fundamentales para representar espacialmente la distribución de la oferta.

5.1.2.2. *Características del establecimiento*

Este grupo de variables describe aspectos estructurales u organizativos del hotel:

- **unidades_alojativas**: número de habitaciones o unidades ofertadas por el establecimiento.
- **ubicación**: clasificación cualitativa de la localización del hotel según criterios turísticos, pudiendo ser Urbano, Vacacional, Interior, o combinaciones de estos.

- **mercado:** segmento de mercado al que se dirige el hotel (Golf, Termal, Solo Adultos, etc.). Se trata de una variable con un alto porcentaje de valores ausentes.
- **área:** superficie de la habitación en metros cuadrados. Presenta una alta variabilidad, con valores que oscilan desde habitaciones pequeñas hasta suites de lujo.
- **tipo_cancelación:** política de cancelación asociada al precio consultado. Inicialmente presenta diversas denominaciones (en español e inglés), que se han unificado en tres categorías: Cancelación Gratuita, No Reembolsable y Condiciones Especiales.

5.1.2.3. Variables de valoración y reputación

Estas variables cuantifican la percepción de los clientes sobre distintos aspectos del servicio, y están expresadas generalmente en una escala porcentual (de 0 a 100):

- **reputación:** puntuación global asignada al hotel por los usuarios, agregando distintos factores de valoración.
- **limpieza, personal, instalaciones_y_servicios, confort, relación_calidad_precio, ubicacion.1, wifi_gratis:** valoraciones específicas que reflejan la opinión de los usuarios respecto a aspectos concretos del establecimiento. Estas variables permiten estudiar qué atributos tienen mayor influencia sobre el precio o la reputación general.

5.1.2.4. Temporalidad y precios

Estas variables permiten analizar la evolución temporal de los precios y el comportamiento del consumidor:

- **fecha_lectura:** fecha en la que se ha realizado la consulta del precio. Se asume como fecha de reserva simulada.
- **fecha_check_in:** fecha estimada de entrada al hotel. Corresponde al día que se desea realizar la estancia.
- **antelación:** número de días entre la fecha_lectura y la fecha_check_in. Refleja con cuánta anticipación se realiza la reserva, y puede tener un efecto significativo sobre el precio final.

- **precio:** Precio ofertado para la estancia en la fecha seleccionada. Expresado en euros.
- **precio_minimo_antelacion:** precio mínimo registrado para ese mismo hotel con la misma antelación, considerando otras fechas. Esta variable se ha calculado para analizar posibles estrategias de descuento o penalización por reserva tardía.
- **numero_reviews:** cantidad total de reseñas asociadas al hotel en la fecha de la consulta. Puede utilizarse como proxy de popularidad o volumen de experiencia compartida.

Una parte esencial del análisis exploratorio consiste en la detección y cuantificación de los valores nulos o ausentes en el conjunto de datos. En la Tabla 2 se presentan las variables con mayor proporción de valores nulos, lo que permitió priorizar su tratamiento en la fase de preprocesamiento.

Tabla 2. *Cantidad de faltantes por variable*

Variable	Valores nulos
mercado	1.095.374
limpieza	54.281
personal	54.281
instalaciones_y_servicio	54.281
confort	54.281
relacion_calidad_precio	54.281
ubicacion.1	54.281
wifi_gratis	68.075
latitud / longitud	17.414
codigo_postal	9.714
unidades_alojativas	3.008
area	21.206
numero_reviews	558

Fuente: elaboración propia

El resto de las columnas presenta valores completos, sin registros nulos. Las variables con mayor porcentaje de ausencia son mercado (95,9 % de valores perdidos) y un grupo de variables de evaluación como limpieza, confort, wifi_gratis, etc., todas con una tasa de nulos cercana al 5 %.

Se detecta también la existencia de registros duplicados, lo que puede indicar que un mismo establecimiento aparece varias veces con información repetida, o bien que existen múltiples observaciones para distintas fechas o condiciones. En total, se encontraron 89.164 duplicados exactos dentro del conjunto de datos. Si bien su tratamiento dependerá del objetivo del análisis (por ejemplo, si se trabaja con precios por noche en distintos momentos o reservas individuales), se considera este dato como un primer indicador de redundancia en los datos, y se tendrá en cuenta al filtrar registros en las siguientes fases.

Además de los nulos y duplicados, se analizan los valores únicos de ciertas columnas categóricas, lo que permite conocer la diversidad de datos disponibles. Por ejemplo:

- **nombre:** 2.577 establecimientos distintos.
- **municipio:** 593 municipios representados.
- **region:** 19 regiones diferentes (17 Comunidades Autónomas + Ceuta y Melilla)
- **tipo_cancelacion:** inicialmente 6 variantes, homogeneizadas a 3.
- **area:** valores muy variados, con más de 100 tamaños distintos de habitación.

Estos recuentos permiten valorar la granularidad del *dataset* y preparar agrupaciones para el análisis posterior (por ejemplo, análisis por región, por tipo de cancelación, etc.).

5.1.3. Estadística descriptiva general y tratamiento de valores atípicos

Una vez completadas las tareas de depuración y estandarización de los datos, se procede al análisis descriptivo de las principales variables numéricas. Esta fase del estudio tiene como objetivo comprender la distribución de los datos, identificar posibles sesgos o anomalías, y establecer un diagnóstico inicial sobre la estructura del conjunto de datos, que será esencial para el desarrollo de modelos posteriores.

En primer lugar, se ha realizado un estudio estadístico básico de las variables más relevantes. La variable objetivo, el precio, presenta una media de 340,98 euros y una mediana de 190,95 euros, lo que revela una clara asimetría positiva en su distribución. El valor mínimo registrado es de 16 euros, mientras que el máximo alcanza los 18.716,4 euros, una cifra inusualmente elevada que sugiere la presencia de valores atípicos extremos. Este fenómeno se confirma al analizar la desviación típica, que asciende a 1752,62 euros, una magnitud considerable en comparación con la mediana, lo que indica una alta dispersión de los datos. Otras variables numéricas relevantes, como el número de reseñas o el tamaño de la habitación (expresado en metros cuadrados), muestran también una gran variabilidad. El número medio de reseñas por establecimiento es de 3.332, con una mediana de 2.699 y un valor máximo superior a 25.000, lo que podría corresponder a hoteles de gran capacidad o a errores de agregación. En cuanto al área, la media se sitúa en torno a los 31,77 m², aunque se han detectado valores extremos superiores a los 1.000 m², posiblemente atribuibles a suites de lujo o entradas incorrectas.

Las variables relacionadas con la reputación y las valoraciones específicas del establecimiento (como limpieza, relación calidad-precio o ubicación) presentan una distribución más compacta y centrada en valores altos. Por ejemplo, la puntuación media de reputación general es de 84,76 sobre 100, y la valoración del servicio WiFi gratuito alcanza una media de 84,03. Este patrón es coherente con el comportamiento típico de las plataformas de reseñas, donde los usuarios tienden a valorar positivamente su experiencia, y los establecimientos con puntuaciones deficientes suelen desaparecer o recibir menos visibilidad.

En lo que respecta a la antelación de la reserva, calculada como el número de días entre la fecha de consulta y la fecha estimada de entrada al hotel, se observa un comportamiento diverso. Aunque el valor medio de antelación es de 60,96 días, la mediana se sitúa en tan solo 30 días. Esto se realiza para estudiar la existencia de dos tipos de comportamiento diferenciados: un grupo de usuarios que reserva con gran anticipación, y otro que realiza la reserva de forma más inmediata.


Dada la asimetría y dispersión observadas en la distribución del precio, se considera necesario aplicar un filtrado de valores atípicos antes de proceder con los análisis posteriores. Para ello, se utiliza el percentil 95 como umbral. El valor correspondiente a este percentil es de 654,79 euros, lo que implica que el 95 % de los precios se sitúan por debajo de dicha cantidad. En consecuencia, se han eliminado todos aquellos registros cuyo precio supera ese límite, lo cual supone descartar 55280 observaciones del total original de 1.105.585. El conjunto de datos resultante, tras la eliminación de estos casos extremos, queda constituido por 1.050.305 registros.

La aplicación de este filtrado permite eliminar valores potencialmente distorsionadores, sin comprometer el tamaño ni la representatividad del conjunto de datos. Además, este procedimiento mejora la robustez de los modelos predictivos que se aplicarán posteriormente, al evitar el efecto desproporcionado de precios fuera de escala.

La Figura 10 muestra la distribución de la variable precio, evidenciando una alta concentración en valores bajos y una cola larga hacia la derecha, característica típica de distribuciones sesgadas positivamente.

5.1.4. Análisis gráfico de cada variable y estudio de correlaciones

Figura 10. *Distribución de la variable precio*




Fuente: elaboración propia

Con el conjunto de datos ya depurado y sin valores atípicos extremos, se lleva a cabo una exploración gráfica de las variables numéricas más relevantes. Este análisis visual permite identificar patrones de comportamiento, posibles anomalías y relaciones entre variables que orientarán el proceso posterior de selección de características para los modelos predictivos.

5.1.4.1. *Distribución de la variable precio*

Como se observa en la Figura 11, el diagrama de caja confirma la presencia de valores atípicos, aunque la mayoría de los precios se concentran entre 120 y 280 euros tras la eliminación del 5 % de los valores más extremos.

Figura 11. *Boxplot de la variable precio*



Fuente: elaboración propia

Esta distribución, aunque todavía asimétrica hacia la derecha, es más representativa del comportamiento real del mercado hotelero tras el filtrado.

El diagrama de caja, por su parte, confirma la existencia de algunos valores altos cercanos a los 600€ que, si bien se mantienen dentro del umbral establecido (percentil 95), siguen estando alejados de la mediana. Estas visualizaciones sugieren que el rango habitual de precios es relativamente acotado, con una proporción menor de hoteles que operan en segmentos de mayor precio.

5.1.4.2. *Exploración gráfica de otras variables numéricas*

Las distribuciones del resto de variables numéricas presentan formas diversas, en general con un único pico o concentración dominante. Por ejemplo, la variable *antelación* muestra una clara dualidad: por un lado, un grupo numeroso de reservas realizadas con poca antelación (menos de 30 días), y por otro, un grupo de menor tamaño pero relevante, compuesto por reservas hechas con varios meses de anticipación. Esta distribución, aunque no estrictamente bimodal, sí evidencia la existencia de diferentes perfiles de comportamiento entre los usuarios.

El número de reseñas, por su parte, tiende a concentrarse en los valores bajos y medios, aunque se identifican establecimientos con volúmenes de reseñas considerablemente altos, que podrían corresponder a grandes cadenas hoteleras o a alojamientos con larga trayectoria en plataformas de opinión. El tamaño de la habitación (*area*) muestra una distribución moderadamente asimétrica, centrada en valores entre 20 y 35 m², pero con una cola derecha que incluye habitaciones excepcionalmente grandes.

En cuanto a las variables de valoración subjetiva (*relacion_calidad_precio*, *ubicacion.1*, *wifi_gratis*, etc.), sus distribuciones están claramente sesgadas hacia la parte superior del rango (valores entre 80 y 95 puntos), reflejando el sesgo positivo característico de las reseñas voluntarias en entornos digitales. Esta concentración en valores altos puede limitar la capacidad discriminante de dichas variables, aunque algunas de ellas muestran suficiente variabilidad como para ser consideradas en etapas posteriores del análisis.

5.1.4.3. *Estudio de correlaciones y detección de redundancia*

Con el fin de comprender las relaciones existentes entre las distintas variables numéricas del conjunto de datos, se ha calculado la matriz de correlaciones de Pearson. Este análisis permite identificar dependencias lineales entre pares de variables y anticipar posibles problemas de redundancia o multicolinealidad, los cuales pueden tener efectos negativos en los modelos de regresión.

En primer lugar, se ha evaluado la relación entre el precio (variable objetivo de este estudio) y el resto de las variables numéricas. La correlación entre precio y reputacion es de 0,29, lo cual indica una relación positiva de intensidad media-débil. Este valor sugiere que, en promedio, los hoteles mejor valorados tienden a ofrecer precios algo más elevados, aunque la influencia de la reputación sobre el precio no es tan pronunciada como podría suponerse. La correlación entre el precio y la valoración de la ubicación (ubicacion.1) es algo superior, con un valor de 0,27, también dentro del rango de correlaciones medias. Por otro lado, el tamaño de la habitación (area) presenta una correlación de 0,37, lo cual indica una relación positiva. En cuanto a la antelación (antelacion), la correlación obtenida es de 0,12, lo que revela una relación positiva débil, con contra de la hipótesis de que los precios pueden ser más bajos cuando la reserva se realiza con mayor anticipación.

Más allá de la relación con el precio, el análisis de correlaciones ha permitido detectar un fenómeno relevante de colinealidad entre un conjunto específico de variables relacionadas con la percepción del cliente. En particular, las variables reputacion, personal, limpieza, confort e instalaciones_y_servicios presentan entre sí coeficientes de correlación superiores a 0,80, alcanzando en algunos casos valores cercanos a 1. Estas correlaciones se interpretan como muy fuertes y evidencian que dichas variables están midiendo aspectos altamente solapados de la experiencia del usuario. Por ejemplo, la puntuación otorgada al personal suele estar muy próxima a la de la limpieza o el confort, y todas ellas están estrechamente relacionadas con la reputación general del establecimiento.

Este solapamiento representa un claro problema de multicolinealidad, ya que la inclusión simultánea de estas variables en un modelo predictivo puede dificultar la estimación precisa de los coeficientes, disminuir la estabilidad del modelo y complicar su interpretación. Además,

puede inflar la varianza de los estimadores, provocando resultados poco fiables. Por lo tanto, en etapas de análisis posteriores, se omitirán dichas variables para el estudio.

5.1.5. Análisis regional del precio de los alojamientos

Con el objetivo de profundizar en la estructura territorial del precio de los establecimientos hoteleros, se ha realizado un análisis desagregado por regiones, considerando diferencias tanto geográficas como tipológicas. Este apartado tiene por finalidad identificar patrones regionales relevantes que puedan estar condicionando la fijación de precios en el sector.

La Figura 12 muestra el mapa utilizado para la división territorial, en el que se agrupan los datos en cinco bloques turísticos representativos del contexto español: Atlánticas, Islas Baleares, Islas Canarias, Mediterráneas y Turismo rural.

Figura 12. Mapa de división de regiones utilizadas



Fuente: elaboración propia

A su vez, desglosamos cada una de las regiones en las siguientes Comunidades Autónomas:

- Regiones mediterráneas: Cataluña, Comunidad Valenciana, Murcia y Andalucía.

- Regiones atlánticas: Galicia, Asturias, Cantabria y País Vasco.
- Regiones de turismo rural: Castilla y León, Castilla-La Mancha, Aragón, Extremadura, Navarra y La Rioja.
- Islas Baleares.
- Islas Canarias.

Esta categorización responde tanto a criterios geográficos como a patrones comunes de comportamiento turístico, y permite comparar zonas con modelos de desarrollo turístico diferenciados (turismo insular, rural, vacacional, masificado, etc.). Queda excluida la Comunidad de Madrid debido a que presenta características únicas (comunidad de interior, pero no rural, patrimonio cultural e histórico únicos, etc.) que no permiten establecer similitudes con otras provincias.

Con el fin de obtener un análisis robusto y representativo, se aplicó un filtrado de precios basado en el percentil 95 de cada conjunto regional, eliminando el 5 % superior de valores extremos, potencialmente distorsionadores. Este tratamiento permitió conservar entre el 90 % y el 95 % de los registros por región, lo que garantiza una muestra suficiente para el análisis sin sacrificar calidad estadística.

Adicionalmente, en las regiones donde fue posible, se ha incorporado una clasificación de los alojamientos en dos categorías tipológicas: urbano y vacacional, basándose en la variable *ubicación* y en un mapeo manual de los municipios más representativos de cada tipo. Esta distinción permite contrastar el comportamiento del precio en entornos urbanos frente a destinos turísticos tradicionales, enriqueciendo la interpretación de los resultados.

Para cada una de las regiones analizadas, se presentarán los siguientes elementos:

- Media y mediana del precio de los alojamientos tras el filtrado.
- Comparación entre alojamientos urbanos y vacacionales, en términos de precio.
- Mención a variables complementarias de interés, como la reputación media de los establecimientos y la superficie media de las habitaciones.

- Interpretación razonada de los resultados, atendiendo a factores contextuales o estructurales propios de cada zona.

5.1.5.1. *Región Mediterránea*

La región mediterránea, conformada por Cataluña, Comunidad Valenciana, Murcia y Andalucía, concentra una parte sustancial de la oferta turística española. Su carácter eminentemente costero y la coexistencia de destinos urbanos de primer nivel, como Barcelona, Valencia, Málaga o Sevilla, la convierten en un área particularmente heterogénea desde el punto de vista hotelero.

El conjunto de datos analizado, tras aplicar el filtrado de outliers por percentil 95, contiene 522.314 registros, lo que permite realizar un estudio detallado y representativo. Los resultados muestran un precio medio de 419,82 €, frente a una mediana de 195,85 €, lo que pone de manifiesto una distribución fuertemente asimétrica, condicionada por la presencia de establecimientos de alta gama con tarifas muy superiores a la media del mercado.

Una de las dimensiones más reveladoras del análisis es la comparación entre los alojamientos de carácter urbano y vacacional, clasificación obtenida a partir de la variable ubicación y un mapeo manual de municipios. En los destinos urbanos, el precio medio asciende a 563,15 €, mientras que en los alojamientos vacacionales se sitúa en 217,88 €. Las diferencias se mantienen también al observar las medianas: 232,19 € en el entorno urbano frente a 161,00 € en el vacacional. Esta disparidad puede atribuirse al perfil de la demanda y al tipo de oferta disponible en cada entorno. En las ciudades predominan los hoteles de cadena, con servicios estandarizados y orientados tanto al turismo como al público corporativo, lo que eleva el rango de precios. Por el contrario, el ámbito vacacional presenta una mayor diversidad de tipologías, incluyendo establecimientos más sencillos o de gestión familiar, que tienden a competir por precio en mercados estacionales.

Junto al precio, otras variables permiten caracterizar mejor estas diferencias. La superficie de las habitaciones (área) tiende a ser mayor en los alojamientos vacacionales, donde las limitaciones de espacio son menores y es habitual encontrar habitaciones amplias o incluso apartamentos turísticos integrados en la oferta hotelera. En cambio, en los hoteles urbanos las habitaciones suelen optimizar el espacio, especialmente en zonas céntricas. En lo relativo

a la reputación, ambas categorías presentan puntuaciones elevadas, aunque ligeramente superiores en los alojamientos urbanos, lo que podría deberse a una mayor estandarización de los procesos de calidad o a una presencia más frecuente de marcas hoteleras con buena imagen en plataformas digitales.

En conjunto, los datos reflejan la dualidad del turismo mediterráneo: por un lado, destinos urbanos con precios más altos y estándares más homogéneos; por otro, enclaves vacacionales con una oferta más diversa y competitiva. Esta segmentación interna sugiere que, en el contexto de modelización, la variable ubicación (o factores correlacionados como el municipio o la densidad turística) adquiere una relevancia sustantiva para explicar el comportamiento del precio en esta región.

5.1.5.2. Región Atlántica

La región atlántica incluye las comunidades de Galicia, Asturias, Cantabria y el País Vasco. A diferencia del modelo turístico intensivo que caracteriza al litoral mediterráneo, el norte peninsular presenta una estructura más equilibrada entre destinos urbanos y vacacionales, con una oferta que combina ciudades de tamaño medio, enclaves costeros con tradición veraniega y un creciente interés por el turismo gastronómico y cultural.

El conjunto de datos depurado para esta zona está formado por 117.345 registros, tras aplicar el filtrado por percentil 95 sobre los precios. A partir de esta muestra, se observa un precio medio de 178,36 € y una mediana de 140,16 €, valores significativamente más bajos que en el caso mediterráneo. Esta menor dispersión y nivel de precios responde en buena parte a un enfoque turístico menos orientado al lujo o a la demanda internacional de alto poder adquisitivo.

También en esta región se ha llevado a cabo una diferenciación entre alojamientos urbanos y vacacionales, empleando tanto la variable ubicación como un mapeo específico por municipios. En los alojamientos urbanos, el precio medio es de 179,81 € y la mediana alcanza los 141,55 €, mientras que en los alojamientos vacacionales los valores son ligeramente inferiores: media de 172,13 € y mediana de 140,00 €. A diferencia de lo observado en el Mediterráneo, la brecha entre ambos segmentos es muy reducida, lo que sugiere una oferta más homogénea y una menor polarización del mercado por tipo de destino. Este

comportamiento podría explicarse por el hecho de que muchas localidades turísticas del norte, como Sanxenxo, Ribadesella o Zarautz, presentan un modelo de alojamiento similar al urbano en términos de calidad, capacidad y servicios ofertados.

En cuanto a otras variables de interés, se detectan algunas diferencias. Por ejemplo, los establecimientos urbanos suelen tener menor superficie media en sus habitaciones que los vacacionales, aunque las diferencias no son tan pronunciadas como en otras regiones. Respecto a la reputación, ambos segmentos mantienen valores altos y comparables, con una ligera ventaja para los alojamientos vacacionales en aspectos como tranquilidad, entorno natural o trato personalizado, que suelen valorarse más en destinos no urbanos.

En conjunto, el análisis de la región atlántica evidencia una estructura más compacta en términos de precios y características, con una menor desigualdad entre destinos urbanos y vacacionales. Esta homogeneidad puede facilitar la construcción de modelos predictivos más estables en esta zona, aunque también implica una menor varianza explicable exclusivamente por el tipo de ubicación.

5.1.5.3. Regiones de Turismo Rural

Las regiones incluidas en esta categoría —Castilla y León, Castilla-La Mancha, Aragón, Extremadura, Navarra y La Rioja— comparten una orientación preferente hacia el turismo de interior, con predominio de enclaves rurales, patrimoniales o de naturaleza. Aunque también albergan capitales provinciales con cierta actividad turística, la mayoría de los establecimientos están ubicados en municipios de tamaño medio o pequeño, lo que configura un panorama hotelero muy distinto al de las zonas costeras.

El conjunto de datos depurado para estas regiones asciende a 165.222 registros, tras eliminar los valores correspondientes al 5 % superior de precios mediante el filtrado por percentil 95. Dentro de este grupo, el precio medio de los alojamientos se sitúa en 148,39 €, mientras que la mediana alcanza los 122,00 €. Estos valores, notablemente inferiores a los de las regiones analizadas anteriormente, reflejan una oferta centrada en precios moderados, con menor presencia de establecimientos de lujo o tarifas premium.

A diferencia de las regiones anteriores, la distinción entre alojamiento urbano y vacacional pierde algo de relevancia, dado que buena parte de los hoteles rurales escapan a ambas categorías tradicionales. No obstante, se han identificado municipios con mayor densidad de población o perfil administrativo (como Zaragoza, Burgos, Cáceres o Logroño), que permiten una aproximación funcional al concepto de “urbano”. Incluso bajo esa premisa, las diferencias entre segmentos son muy limitadas, lo que refuerza la hipótesis de una oferta hotelera más uniforme en términos de precios, servicios y orientación al cliente.

En lo relativo a otras variables, cabe destacar que la superficie media de las habitaciones tiende a ser algo más elevada que en entornos urbanos, lo que responde tanto a la disponibilidad de espacio como a una orientación hacia el confort del cliente en estancias más prolongadas. Las puntuaciones de reputación se mantienen altas, con una media próxima a los 85 puntos, y no se observan grandes diferencias entre localidades. Este dato es coherente con el modelo de turismo de proximidad y escapada de fin de semana, donde la experiencia subjetiva cobra especial importancia y los hoteles de tamaño reducido suelen contar con una atención más personalizada.

En resumen, las regiones de turismo rural presentan una estructura de precios contenida y homogénea, con escasa dispersión y diferencias mínimas por tipo de ubicación. Este comportamiento refleja una oferta menos segmentada y más orientada al equilibrio coste-beneficio, lo que puede facilitar la modelización general del precio, pero limitar la capacidad explicativa de variables como la ubicación o el número de reseñas.

5.1.5.4. Análisis conjunto: Islas Baleares y Canarias

Las regiones insulares, representadas en este estudio por Islas Baleares y Canarias, configuran un bloque diferenciado dentro del panorama turístico nacional. Ambas destacan por su elevada dependencia del sector turístico, una clara orientación hacia el visitante internacional y una fuerte estacionalidad suavizada por el clima favorable. No obstante, presentan también diferencias relevantes en estructura de precios, perfil de alojamientos y distribución territorial de la oferta.

Tras aplicar el filtrado por percentil 95, se dispone de 48.560 registros para las Islas Baleares y 81.135 registros para Canarias, lo que permite una comparación robusta entre ambos

archipiélagos. En el caso balear, el precio medio se sitúa en 242,75 €, con una mediana de 209,78 €. Por su parte, Canarias alcanza una media de 296,92 € y una mediana de 273,96 €, situándose, así como la región con los precios más altos de todo el estudio.

Esta diferencia puede atribuirse a diversos factores. En primer lugar, la estructura de la demanda: mientras Baleares concentra una mayor parte de su actividad en los meses de verano, Canarias mantiene una demanda más estable durante todo el año, especialmente vinculada al turismo europeo que busca clima templado en invierno. En segundo lugar, el modelo de alojamiento: en Canarias es más frecuente encontrar complejos turísticos integrales y resorts de gama alta, con servicios exclusivos y estancias prolongadas, lo que contribuye a elevar el precio medio.

La variable ubicación permite clasificar una parte significativa de los establecimientos como vacacionales, especialmente en localidades como Playa del Inglés, Costa Adeje, Calvià o Alcúdia. En menor medida, se identifican enclaves urbanos (como Palma o Las Palmas de Gran Canaria), aunque su peso relativo es inferior. Aun así, incluso entre los alojamientos de carácter urbano, los precios en Canarias superan a los de Baleares, tanto en media como en mediana, lo que refuerza la hipótesis de una estructura de precios más alta y consolidada.

En cuanto a variables complementarias, se observa que la superficie media de las habitaciones es ligeramente superior en Baleares, mientras que la reputación general es algo más elevada en Canarias, especialmente en aspectos como la relación calidad-precio y el trato del personal. Estos matices sugieren que, si bien ambas regiones compiten en un mercado similar, presentan posicionamientos diferenciados: Baleares con una oferta más estandarizada y orientada a la temporada alta, y Canarias con un enfoque más diversificado y de mayor valor añadido.

En conjunto, el análisis de ambos archipiélagos permite concluir que la insularidad, el perfil de la demanda internacional y la especialización en productos turísticos de alto nivel son factores clave que elevan el precio medio respecto a la península. No obstante, la estructura interna de la oferta, los niveles de reputación y la orientación estacional generan diferencias claras que justifican un tratamiento separado en fases posteriores del análisis predictivo.

5.1.6. Comparación regional del impacto de las variables reputación y área

A partir de las matrices de correlación generadas para cada subconjunto regional, se ha evaluado la relación entre el precio y dos variables clave: la reputación del establecimiento y el área de la habitación. La tabla anterior muestra los coeficientes de correlación de Pearson y Spearman para ambas variables, permitiendo identificar diferencias en la fuerza de asociación según el contexto geográfico.

Los resultados revelan que el área de la habitación presenta una relación más fuerte y consistente con el precio que la reputación, especialmente en las regiones insulares. En Canarias, el coeficiente de correlación de Pearson alcanza un valor de 0,50 y de 0,51 con Spearman, el más alto del conjunto, lo que indica una asociación clara entre habitaciones más amplias y precios más elevados. Este patrón se repite en Baleares, con correlaciones de 0,47 (Pearson) y 0,46 (Spearman). Esta fuerte dependencia sugiere que, en entornos insulares donde la oferta de gama alta es predominante, el tamaño de la habitación constituye un diferenciador clave en la política de precios.

Por su parte, las regiones peninsulares muestran una relación más moderada entre área y precio. Aun así, Turismo Rural presenta valores destacables (0,42 y 0,43), lo que indica que, incluso en alojamientos más sencillos, el espacio disponible es un atributo apreciado por el cliente y valorado económicamente. En el caso de Atlántico y Mediterráneo, las correlaciones son más bajas pero consistentes (alrededor de 0,35), lo que puede reflejar una mayor homogeneidad en las dimensiones de los alojamientos urbanos y vacacionales de estas zonas.

En cuanto a la reputación, los coeficientes se sitúan en un rango más estrecho y homogéneo, con valores comprendidos entre 0,30 y 0,36 (Pearson). El mayor impacto se observa en la región mediterránea y en Baleares, donde la reputación parece influir más directamente sobre el precio. En las regiones rurales y atlánticas, aunque también se constata una relación positiva, esta es algo más débil, lo que sugiere que otros factores —como la localización o la temporalidad— podrían tener un peso relativo mayor.

Por último, las correlaciones de Spearman corroboran los patrones anteriores, indicando que las relaciones no necesariamente lineales entre precio y variables clave se mantienen estables, con el área como variable más determinante en todas las regiones. Esto refuerza la idea de

que el tamaño del alojamiento es una característica estructural que afecta al precio de forma más directa que la percepción subjetiva de calidad recogida en la reputación.

En conjunto, los resultados, agrupados y resumidos en la Tabla 3, confirman que, aunque ambas variables son relevantes, el área de la habitación es un predictor más potente y estable del precio en prácticamente todas las regiones, especialmente en los archipiélagos. La reputación, aunque importante, muestra un efecto más difuso, posiblemente condicionado por la segmentación del mercado, el perfil del turista y el tipo de canal de reserva utilizado.

Tabla 3. *Tabla de correlaciones por regiones*

Región	Pearson - Reputación	Pearson - Área	Spearman - Reputación	Spearman - Área
Mediterráneo	0,36	0,35	0,32	0,33
Atlántico	0,30	0,35	0,32	0,39
Turismo Rural	0,32	0,42	0,36	0,43
Islas Baleares	0,36	0,47	0,32	0,46
Islas Canarias	0,34	0,50	0,32	0,51

Fuente: elaboración propia

5.1.7. Influencia de la reputación en Booking sobre el precio: análisis predictivo

El objetivo de este subapartado es evaluar hasta qué punto la reputación del establecimiento en Booking permite explicar o predecir su precio. Para ello, se ha planteado un estudio comparativo mediante distintos modelos de regresión aplicados tanto al conjunto general como a cada una de las regiones analizadas en apartados anteriores. La variable de entrada es la puntuación global de reputación (de 0 a 100), y la variable objetivo es el precio del alojamiento.

Los modelos empleados son los siguientes:

- **Regresión lineal simple**, que estima una relación lineal directa entre reputación y precio.

- **Regresión polinómica de segundo grado**, que permite detectar posibles curvaturas en la relación.
- **Random Forest**, modelo de tipo no paramétrico, que capta relaciones complejas y no lineales sin necesidad de asumir una forma funcional determinada.

La Tabla 4 muestra los resultados obtenidos al analizar la influencia de la reputación sobre el precio mediante diferentes modelos. Se observa que, aunque los valores de R^2 son bajos, Random Forest presenta el mejor ajuste ($R^2 = 0,10$), frente a la regresión lineal y polinómica.


Tabla 4. Resultados influencia reputación con diferentes modelos

Modelo	R^2	MAE	RMSE
Regresión Lineal	0,08	93,09	118,96
Regresión Polinómica (g2)	0,09	92,13	118,13
Random Forest	0,10	91,67	117,69

Fuente: elaboración propia

En la Figura 13 se representa gráficamente la relación entre reputación y precio, comparando la regresión lineal, la polinómica (grado 2) y Random Forest. El comportamiento no lineal queda evidenciado en el ajuste superior de Random Forest frente a los modelos lineales.

Figura 13. *Influencia de la reputación sobre el Precio*



Fuente: elaboración propia

Estos resultados indican que la reputación explica solo una pequeña parte de la variabilidad del precio (R^2 en torno al 10 %), independientemente del modelo utilizado. Aunque el rendimiento mejora ligeramente con modelos más complejos como el Random Forest, las mejoras son marginales. Esto sugiere que, aunque existe una relación positiva entre reputación y precio, esta no es lo suficientemente fuerte como para considerarla un predictor principal en ausencia de otras variables.

La Tabla 5 presenta los valores de R^2 por región, destacando que las zonas insulares (Baleares y Canarias) alcanzan los mejores ajustes, especialmente con Random Forest, que llega a 0,18 en Canarias.

Al repetir el análisis de regresión para cada una de las regiones geográficas definidas, se observan variaciones en el grado de influencia de la reputación sobre el precio. A continuación, se resumen los coeficientes R^2 de los tres modelos por región:

Tabla 5. Resultados del grado de influencia de la reputación sobre el precio

Región	Lineal	Polinómica (g2)	Random Forest
Mediterráneo	0,10	0,10	0,11
Atlántico	0,09	0,09	0,12
Turismo Rural	0,10	0,14	0,15
Islas Baleares	0,12	0,14	0,15
Islas Canarias	0,11	0,13	0,18

Fuente: elaboración propia

Esto indica que, en estos contextos turísticos altamente competitivos y orientados a la calidad del servicio, la reputación tiene una mayor capacidad explicativa sobre el precio.

Por el contrario, en las regiones atlánticas y rurales, el peso de la reputación como variable predictiva es más limitado. En estos entornos, la diversidad del tipo de alojamiento, la dispersión geográfica y el menor protagonismo de las plataformas digitales pueden reducir la influencia directa de la puntuación de Booking sobre el precio final.

En conjunto, los resultados permiten afirmar que la reputación en Booking influye sobre el precio del alojamiento, pero no lo determina de forma dominante. Por tanto, si bien la reputación debe considerarse una variable relevante dentro del conjunto de predictores del precio, su capacidad predictiva individual es limitada, y mejora sustancialmente cuando se combina con otras variables como el área de la habitación, la localización o la categoría del establecimiento.

En la sección posterior, vamos a generar distintos modelos que podamos empezar para predecir la variable precio.

5.2. Modelado predictivo del precio

Una vez completado el análisis exploratorio, este capítulo aborda el desarrollo de modelos predictivos orientados a estimar el precio de los alojamientos turísticos a partir de un conjunto de variables previamente depuradas. El objetivo es evaluar qué técnicas resultan más eficaces para capturar la complejidad de esta variable, y qué atributos del hotel, su ubicación o su valoración afectan más significativamente a la fijación de precios.

Para ello se han seleccionado diversos modelos, agrupados en función de su enfoque metodológico y nivel de complejidad:

5.2.1.1. Modelos tradicionales

Regresión lineal múltiple, por su valor interpretativo, simplicidad y como punto de partida para evaluar mejoras posteriores. Este modelo estima una relación lineal entre el precio y un conjunto de variables predictoras, bajo supuestos clásicos como la homocedasticidad y la independencia de errores.

5.2.1.2. Modelos de aprendizaje automático

Random Forest Regressor: Se trata de un modelo de tipo ensamble basado en árboles de decisión. Random Forest construye múltiples árboles de regresión sobre subconjuntos aleatorios del conjunto de entrenamiento y de las variables predictoras, y combina sus predicciones mediante una media. Esta técnica mejora significativamente la estabilidad y precisión respecto a un único árbol, al reducir el sobreajuste (*overfitting*) mediante la agregación de modelos débiles. Es particularmente eficaz para capturar relaciones no lineales y efectos de interacción entre variables.

- XGBoost Regressor: XGBoost (*Extreme Gradient Boosting*) es una técnica de *boosting* basada en gradientes que optimiza la predicción mediante la construcción secuencial de árboles, cada uno corrigiendo los errores del anterior. Utiliza una función de pérdida diferenciable, técnicas de regularización L1 y L2, y una estrategia de podado optimizada para mejorar la generalización del modelo. Es ampliamente reconocida por su alto rendimiento en tareas de predicción tabular, y ha sido utilizada con éxito en múltiples competiciones y entornos productivos debido a su balance entre precisión, velocidad de entrenamiento y control del sobreajuste.

5.2.1.3. *Modelo basado en redes neuronales*

Se entrenará una red neuronal artificial para predecir el precio, utilizando una arquitectura secuencial compuesta por múltiples capas densas con funciones de activación no lineales. Se aplicarán técnicas de regularización como el dropout y la normalización de entrada para mejorar la capacidad de generalización. Se documentarán los hiperparámetros clave y se evaluará su rendimiento frente al resto de modelos en términos de error de predicción y capacidad de aprendizaje.

Finalmente, se incluirá una sección dedicada a la evaluación y comparación de todos los modelos, atendiendo a métricas como el coeficiente de determinación R^2 , el error absoluto medio (MAE) y el error cuadrático medio (RMSE). Asimismo, se detallarán los ajustes y técnicas empleadas en la fase de entrenamiento, lo que permitirá valorar la eficacia real de cada modelo en condiciones comparables.

5.2.2. Transformaciones del conjunto de datos para el modelado

En las fases anteriores del análisis, el conjunto de datos se había mantenido estructuralmente próximo a su forma original, aplicando únicamente transformaciones necesarias para limpieza, conversión de tipos y filtrado de valores atípicos. Sin embargo, en esta etapa, se ha generado una nueva versión del conjunto de datos, adaptada específicamente a la tarea de predicción del precio. Esta versión, que constituye la base para todos los modelos de este capítulo, contiene ya las columnas codificadas y ajustadas a los requisitos de cada técnica.

A continuación, se describen las principales operaciones de transformación realizadas, con la salvedad de que algunas de ellas se aplican directamente en la fase de entrenamiento de cada modelo (por ejemplo, el escalado), para mantener la trazabilidad del conjunto original.

5.2.2.1. *Codificación de variables categóricas*

Se ha empleado One-Hot Encoding para variables como *ubicación*, *tipo_cancelación* y *region*, lo que ha generado un conjunto de columnas binarias que indican la pertenencia a cada categoría. Este tipo de codificación evita introducir relaciones ficticias entre valores no ordinales y permite que los algoritmos trabajen con información cualitativa de forma adecuada.

Por otra parte, variables como provincia y municipio han sido tratadas mediante Label Encoding, generando valores enteros que identifican inequívocamente cada categoría. Para asegurar la trazabilidad, se ha conservado un diccionario de equivalencias, aunque estas variables han sido utilizadas exclusivamente como identificadores internos y no como variables predictoras.

5.2.2.2. *Normalización y escalado de variables numéricas*

El escalado de variables numéricas (como el precio, el área, la reputación o el número de reseñas) se realiza en el interior de cada modelo, justo antes del entrenamiento, utilizando transformaciones estándar como StandardScaler. Esto garantiza la estabilidad numérica de los algoritmos y permite comparar resultados bajo condiciones homogéneas sin alterar el *dataset* original. De esta forma, se conserva la interpretabilidad de los datos cuando es necesario, y se preserva su estructura para análisis exploratorios.

5.2.2.3. *Ingeniería de variables temporales*

Se ha creado una variable continua fecha que representa el número de días desde una fecha mínima de referencia. Además, se han generado variables derivadas como el día de la semana, con el fin de capturar patrones temporales que puedan tener un efecto sobre el precio (por ejemplo, diferencias entre fines de semana y días laborables). Estas transformaciones temporales permiten incorporar la estacionalidad y los efectos cíclicos de forma explícita.

5.2.2.4. *Eliminación de variables redundantes o de baja relevancia*

Se han eliminado varias columnas que no aportaban valor predictivo directo o que podían inducir ruido en el entrenamiento:

- **nombre:** por ser un identificador explícito que no generaliza entre alojamientos.
- **mercado:** presentaba más del 95 % de valores ausentes, y no aportaba información fiable.
- **latitud y longitud:** aunque técnicamente relevantes, esta información geográfica ya se encuentra codificada implícitamente a través del código postal, así como de las variables provincia, municipio y región.

5.2.3. Modelos tradicionales

5.2.3.1. Regresión lineal múltiple

Como punto de partida para la predicción del precio, se ha optado por la aplicación de un modelo de regresión lineal múltiple, una técnica clásica ampliamente utilizada por su simplicidad, interpretabilidad y eficacia en problemas donde las relaciones entre variables pueden aproximarse mediante funciones lineales.

El objetivo del modelo es encontrar los coeficientes que minimicen la suma de los errores cuadráticos (MSE) entre las predicciones y los valores reales.

En este caso, las variables predictoras incluyeron atributos estructurales del alojamiento (categoría, unidades_alojativas, área), variables de valoración (reputación), codificaciones geográficas (región, provincia, municipio), y la ubicación cualitativa (urbano, vacacional, etc.). Las variables categóricas se codificaron previamente mediante One-Hot Encoding y las numéricas fueron normalizadas dentro del modelo para garantizar la comparabilidad de coeficientes.

El modelo se entrenó sobre el conjunto de entrenamiento utilizando las variables codificadas y normalizadas, y se evaluó sobre un conjunto de validación independiente. Se obtuvo un coeficiente de determinación (R^2) de 0,41. Estos resultados muestran que, aunque la regresión lineal múltiple consigue capturar una parte significativa de la variabilidad del precio (un 41 %), presenta limitaciones claras al tratarse de un modelo lineal. La diferencia entre el MAE y el RMSE sugiere además que existen errores puntuales elevados (*outliers*) que afectan al rendimiento general, especialmente en segmentos de precio más alto o bajo.

Uno de los principales puntos fuertes de la regresión lineal múltiple reside en su carácter interpretativo. A diferencia de otros modelos, este enfoque permite examinar con claridad cómo influye cada variable independiente en la predicción del precio, facilitando así la extracción de conclusiones cuantitativas relevantes y contrastables.

Los coeficientes estimados reflejan la magnitud y el sentido del impacto de cada variable sobre el precio, bajo el supuesto de que las demás se mantienen constantes. En este sentido, el análisis de los resultados obtenidos confirma varias de las hipótesis planteadas durante la fase

exploratoria, especialmente en lo relativo al peso de la reputación, el tamaño del alojamiento y la ubicación.

La variable más influyente, en términos absolutos, es la reputación del establecimiento, cuya puntuación se basa en la valoración agregada realizada por los usuarios. El coeficiente estimado asociado a esta variable fue de aproximadamente 0,45, lo que indica que, por cada punto adicional en la escala de reputación (de 0 a 100), el precio se incrementa en 0,45 unidades en términos normalizados. Esta relación positiva confirma que los alojamientos mejor valorados tienden a posicionarse en segmentos de precio más elevados, presumiblemente por el valor percibido por los consumidores o por una estrategia de precios coherente con su posicionamiento de calidad.

En segundo lugar, destaca la superficie de la habitación (area), con un coeficiente de aproximadamente 0,26. Este valor sugiere que existe una relación directa entre el tamaño del alojamiento y el precio ofertado, si bien la intensidad del efecto es menor que en el caso de la reputación. Cabe señalar que esta variable ha sido previamente normalizada, por lo que su interpretación debe hacerse en relación con la desviación estándar de los datos originales. Aun así, resulta evidente que el área constituye un determinante importante en la fijación de precios, especialmente en mercados donde el confort y el espacio son atributos diferenciadores.

También resulta significativa la variable relacionada con el tipo de ubicación. En particular, el indicador binario correspondiente a la ubicación vacacional (resultado del One-hot encoding de la variable ubicación) presenta un coeficiente en torno a 0,22, lo que implica que los alojamientos situados en entornos turísticos o de descanso tienden a presentar precios superiores a los ubicados en entornos urbanos o interiores, incluso una vez controlado el efecto de otras variables. Esta observación concuerda con la estacionalidad y la mayor presión de demanda que suelen caracterizar a estas zonas durante épocas concretas del año.

Por su parte, la categoría del establecimiento, medida a través del número de estrellas, arroja un coeficiente positivo cercano a 0,14. Aunque su influencia es menor en comparación con las variables anteriores, sigue siendo estadísticamente significativa y consistente con la lógica del

mercado: los hoteles de mayor categoría tienden a ofrecer servicios adicionales que justifican precios más altos.

En contraposición, otras variables como el número de reseñas o el código postal presentan coeficientes próximos a cero. Esto indica que, si bien pueden contener información contextual relevante, su efecto marginal sobre el precio, una vez incluidas otras variables explicativas más determinantes, es limitado. Este hecho refuerza la necesidad de aplicar técnicas de selección de características o de emplear modelos más complejos capaces de capturar relaciones no lineales o interacciones.

En conjunto, los resultados obtenidos mediante la regresión lineal múltiple ofrecen una primera aproximación fiable y comprensible al fenómeno de la fijación de precios en el sector hotelero. Las variables reputación, área y orientación vacacional destacan como los principales factores explicativos, aportando evidencia empírica a favor de su inclusión prioritaria en modelos más avanzados.

5.2.3.2. *Regresión lineal múltiple*

Dentro de los modelos lineales tradicionales, se ha incluido la regresión Ridge como una extensión de la regresión lineal múltiple que incorpora regularización para reducir el sobreajuste. Este modelo penaliza los coeficientes de regresión a través de una penalización L2, lo que implica añadir un término, α , proporcional a la suma de los cuadrados de los coeficientes en la función de coste.

En el contexto de este trabajo, la regresión Ridge se ha aplicado sobre el conjunto de datos ya transformado, que incluye variables numéricas normalizadas y variables categóricas codificadas mediante One-hot encoding. El valor de α utilizado ha sido 1.0, seleccionado tras pruebas preliminares por su buen equilibrio entre ajuste y capacidad de generalización.

Los resultados obtenidos con este modelo sobre el conjunto de validación reflejan un rendimiento similar a la regresión lineal. El valor de R^2 , 0,45, indica que el modelo Ridge es capaz de explicar aproximadamente el 45 % de la variabilidad en el precio a partir del conjunto de variables predictoras.

5.2.4. Modelos avanzados de aprendizaje automático

En esta sección se presentan los modelos no lineales y no tradicionales utilizados en el estudio, basados en técnicas de aprendizaje automático supervisado. A diferencia de la regresión lineal múltiple, que parte de una relación funcional explícita y lineal entre las variables predictoras y la variable objetivo, estos algoritmos permiten modelar relaciones complejas, no lineales y de alta dimensionalidad, ofreciendo así un mayor potencial predictivo.

Se han seleccionado dos modelos representativos de este enfoque:

- Random Forest Regressor
- XGBoost Regressor

Cada uno de ellos se describe a continuación, indicando brevemente su fundamento teórico, su aplicación sobre el conjunto de datos, y los resultados obtenidos.

5.2.4.1. XGBoost Regressor

El modelo XGBoost (*Extreme Gradient Boosting*) se basa en la técnica del *boosting* por gradiente, que construye un modelo de forma secuencial, añadiendo en cada iteración un nuevo árbol que corrige los errores cometidos por el conjunto anterior.

En este estudio se ha aplicado sobre el conjunto de datos preprocesado, incluyendo la normalización de las variables continuas y la codificación *one-hot* de las categóricas, replicando las condiciones del resto de modelos para una comparación justa.

Los resultados obtenidos en el conjunto de validación han sido los siguientes: el coeficiente de determinación R^2 ha sido de 0,72. Este valor indica que el modelo logra explicar una porción significativa de la varianza del precio, aunque el valor es inferior al que obtuvimos en el caso del Random Forest.

5.2.4.2. Random Forest Regressor

El modelo de Random Forest para regresión pertenece a la familia de algoritmos de ensamblado basados en árboles de decisión. Se fundamenta en la creación de múltiples árboles entrenados sobre diferentes subconjuntos aleatorios del conjunto de datos, utilizando

una técnica conocida como *bootstrap aggregating* o *bagging*. La predicción final del modelo se obtiene como la media de las predicciones individuales de cada árbol, lo que le confiere una gran robustez frente al sobreajuste y una notable capacidad de generalización.

Para este estudio se ha implementado un modelo Random Forest con un número de árboles fijado en 20, y con parámetros adicionales ajustados automáticamente mediante validación cruzada. Las variables predictoras fueron previamente tratadas mediante normalización y codificación categórica (One-hot encoding), siguiendo el mismo preprocesado aplicado al resto de modelos.

Los resultados obtenidos en el conjunto de validación fueron los siguientes: el coeficiente de determinación R^2 alcanzó un valor de 0,89, lo que implica que el modelo es capaz de explicar el 89 % de la varianza observada en la variable precio.

Estos resultados reflejan una mejora sustancial respecto a la regresión lineal múltiple. El método Random Forest ha demostrado una mayor capacidad para capturar las complejidades estructurales del conjunto de datos, especialmente en lo que respecta a interacciones no lineales y heterogeneidad entre regiones y tipos de ubicación.

5.2.5. Modelos basados en redes neuronales

En esta sección se describe el proceso de desarrollo y evaluación de modelos basados en redes neuronales artificiales para la predicción del precio de alojamientos turísticos. Las redes neuronales han sido seleccionadas por su capacidad para modelar las relaciones altamente no lineales y complejas entre las variables de entrada y la variable objetivo, lo cual resulta particularmente útil en contextos donde la fijación de precios puede depender de múltiples factores.

Frente a los modelos tradicionales, las redes neuronales ofrecen una estructura flexible y escalable que permite ajustar tanto la profundidad (número de capas ocultas) como la complejidad (número de unidades por capa) del modelo. Esto las convierte en una alternativa prometedora para abordar problemas donde la relación entre variables no es evidente o está mediada por dependencias cruzadas.

A lo largo de este apartado se detallan las distintas arquitecturas implementadas, así como las decisiones técnicas tomadas para mejorar el rendimiento y la capacidad de generalización de

los modelos entrenados. En concreto, se ha trabajado con redes secuenciales compuestas por capas densas (fully connected), introduciendo mecanismos de regularización como *Dropout* y penalización *L2*, y aplicando técnicas de entrenamiento avanzadas como el *Early Stopping* y la reducción dinámica del *learning rate*.

Además, con el objetivo de garantizar condiciones de entrenamiento adecuadas, se han aplicado procesos de normalización, tanto a las variables predictoras como a la variable objetivo, adaptando el flujo de datos a los requisitos específicos de las redes neuronales. Los resultados obtenidos se presentan mediante métricas comunes como el error absoluto medio (MAE), el error cuadrático medio (MSE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), permitiendo valorar el grado de ajuste alcanzado por cada modelo entrenado. El uso de estas métricas se desarrollará en apartados posteriores.

5.2.5.1. Preprocesamiento específico aplicado

Para entrenar adecuadamente los modelos basados en redes neuronales, ha sido necesario aplicar una serie de transformaciones específicas al conjunto de datos con el objetivo de adaptarlo a los requisitos del aprendizaje profundo. Estas transformaciones se han realizado de forma independiente respecto a las aplicadas en otros modelos del capítulo, manteniendo la coherencia en los datos, pero ajustando el preprocesamiento a las necesidades particulares de este tipo de modelos.

Uno de los aspectos clave en la preparación de los datos ha sido la normalización de las variables de entrada, llevada a cabo mediante *StandardScaler*, una técnica que centra y escala las variables para que presenten media cero y desviación estándar uno. Esta transformación resulta especialmente adecuada para modelos basados en redes neuronales, ya que contribuye a evitar dominancias entre variables, estabiliza el entrenamiento y mejora la velocidad de convergencia del algoritmo de optimización.

Del mismo modo, se ha optado por escalar también la variable objetivo (precio), debido a su amplia variabilidad y distribución asimétrica. Esta decisión, aunque no siempre necesaria en modelos de regresión, se justifica por los beneficios observados empíricamente en términos de precisión y estabilidad del modelo. Tras la inferencia, los valores han sido desescalados para recuperar su interpretación en unidades reales y facilitar el análisis de resultados.

El conjunto de datos se ha dividido en dos subconjuntos: uno para entrenamiento (80%) y otro para validación (20%), utilizando la técnica de *Hold-Out Validation* con una semilla fija para garantizar la reproducibilidad. Tanto el escalado de X como el de y se ha ajustado exclusivamente sobre el conjunto de entrenamiento, aplicando posteriormente la transformación aprendida al conjunto de validación.

5.2.5.2. *Diseño y entrenamiento de las arquitecturas*

En esta sección se detallan algunas de las diferentes arquitecturas de redes neuronales artificiales (ANN) entrenadas para la predicción del precio de los alojamientos turísticos. Cada modelo se ha construido utilizando la API secuencial de Keras (TensorFlow), definiendo capas densamente conectadas (fully connected layers) y aplicando técnicas de regularización para mejorar la capacidad de generalización. A lo largo del proceso, se ha seguido una estrategia iterativa de mejora progresiva, comenzando por una red básica y avanzando hacia estructuras más complejas.

1. Primera arquitectura: red neuronal simple base

El primer modelo se diseñó como una red neuronal simple de referencia. Su arquitectura constaba de:

- Una **capa densa de entrada** con 128 neuronas y función de activación ReLU.
- Una **capa oculta intermedia** de 64 neuronas, también con activación ReLU.
- Una **capa de salida** con una sola neurona lineal, adecuada para tareas de regresión.

Este modelo utilizaba el optimizador Adam con una tasa de aprendizaje fija de 0.001 y una función de pérdida basada en el error absoluto medio (MAE). Aunque, es cierto que ofreció una capacidad inicial aceptable para modelar la variable objetivo, los resultados obtenidos ($MAE \approx 59$, $RMSE \approx 113$, $R^2 \approx 0.86$) no lograron superar a los modelos basados en aprendizaje automático clásico, especialmente a Random Forest, entrenado previamente.

2. Segunda arquitectura: red mejorada con regularización y *dropout*

Para mejorar el rendimiento, se implementó una arquitectura más profunda con técnicas de regularización. Las características principales fueron:

- **Tres capas ocultas densas** con 256, 128 y 64 neuronas respectivamente, todas con función de activación ReLU.

- Se introdujo **regularización L2** en cada capa densa para penalizar pesos excesivamente grandes y reducir el sobreajuste.
- Se aplicó **dropout** entre capas (con valores del 30% y 40%) como técnica para evitar la dependencia excesiva de ciertas neuronas durante el entrenamiento.
- Se mantuvo un optimizador **Adam**, pero se incorporó un **callback de reducción de tasa de aprendizaje (ReduceLROnPlateau)** y **EarlyStopping** para detener el entrenamiento cuando no se detectaban mejoras en la validación.

A pesar de las mejoras estructurales implementadas en esta red neuronal, los resultados obtenidos se situaron en torno a $MAE \approx 55,6$ y $R^2 \approx 0,81$, sin alcanzar el rendimiento del modelo de Random Forest, aunque de los mejores resultados obtenidos haciendo las predicciones de precio mediante el uso de redes neuronales.

3. Tercera arquitectura: red avanzada con normalización de la variable objetivo

En un intento de optimizar aún más la red, se exploró una nueva estrategia que consistía en **escalar también la variable objetivo (y)** mediante StandardScaler. Esta decisión se basó en la hipótesis de que la normalización de los valores de salida facilitaría el aprendizaje de relaciones complejas, al centrar el modelo en predecir desviaciones estandarizadas.

La arquitectura mantenía la profundidad anterior, pero se ajustaron nuevos hiperparámetros:

- **Capas densas con 256, 128 y 64 neuronas**, manteniendo activación *ReLU*.
- Dropout moderado (20%-30%) y regularización L2 más ligera (0,0005).
- Uso de **batch size 128, 200 épocas máximas** y reducción dinámica del learning rate (comenzando en 0.0002 y ajustándose durante el entrenamiento).
- Se evaluaron las métricas tras desescalar las predicciones al dominio original.

Como se observa en la Tabla 6, la red neuronal avanzada, con normalización de la variable objetivo y ajuste dinámico del *learning rate*, obtuvo un rendimiento ligeramente inferior al de la arquitectura anterior, con un R^2 de 0,79 y un MAE de 65,58.

Tabla 6. Resultados en diferentes métricas con la red neuronal avanzada

Modelo	R ²	MAE	RMSE
Red Neuronal Avanzada	0,79	65,58	139,03


Fuente: elaboración propia

5.2.5.3. Comparación de la evolución de la pérdida y el error absoluto medio entre arquitecturas

Con el fin de evaluar el comportamiento y la estabilidad de las redes neuronales entrenadas, se analizó la evolución de la función de pérdida (*loss*, expresada en términos de error cuadrático medio) y del error absoluto medio (MAE) a lo largo de las épocas, tanto en el conjunto de entrenamiento como en el de validación. Estas métricas permiten observar la velocidad de convergencia, la posible aparición de sobreajuste y el grado en que cada arquitectura logra generalizar adecuadamente.

En las Figuras 14, 15 y 16 se muestran las curvas correspondientes a las tres arquitecturas implementadas: el modelo inicial (*Red Neuronal Simple*), el modelo mejorado con regularización y dropout (*Red Neuronal Mejorada*) y el modelo final (*Red Neuronal Final*). El análisis conjunto de estas gráficas facilita comprender cómo las decisiones de diseño y ajuste influyeron en la estabilidad del entrenamiento y en la reducción progresiva del error.


Figura 14. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Simple para la predicción del precio de alojamientos turísticos.



Fuente: elaboración propia

Figura 15. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Mejorada para la predicción del precio de alojamientos turísticos.


R^2 : 0.7389



Fuente: elaboración propia

Figura 16. Evolución de la función de pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento y la validación del modelo Red Neuronal Final para la predicción del precio de alojamientos turísticos.

R^2 : 0.8275



Fuente: elaboración propia

Veamos las conclusiones extraídas de cada una de las gráficas:

1. **Modelo inicial: Red Neuronal Simple** (Figura 14)

En la primera arquitectura se observa una disminución rápida de la pérdida y del MAE durante las primeras épocas, seguida de una estabilización progresiva en ambas métricas. Sin embargo, la curva de validación mantiene una separación evidente respecto a la de entrenamiento, lo que indica que, aunque el modelo mejora en términos generales, no alcanza un ajuste óptimo y presenta cierto sesgo. Esta diferencia sugiere que la capacidad de generalización del modelo es limitada, lo que justifica la necesidad de incorporar mecanismos adicionales para reducir el sobreajuste y mejorar la convergencia.

2. **Modelo intermedio: Red Neuronal Mejorada** (Figura 15)

En la segunda arquitectura, el uso de regularización L2 y dropout produce un comportamiento más controlado. La pérdida y el MAE decrecen de manera estable, y la distancia entre las curvas de entrenamiento y validación se reduce respecto al modelo anterior. Aunque la convergencia es más gradual, el patrón observado refleja una mejora en la estabilidad del aprendizaje y un menor riesgo de sobreajuste, especialmente en la parte final del entrenamiento.

3. **Modelo avanzado: Red Neuronal Final** (Figura 16)

En la arquitectura final, que incluye el escalado de la variable objetivo y ajustes adicionales en hiperparámetros, las curvas muestran la evolución más consistente de todas. Tanto la pérdida como el MAE en validación alcanzan sus valores más bajos, y la brecha entre entrenamiento y validación es mínima, lo que evidencia un ajuste más equilibrado. Además, la convergencia se mantiene estable durante las últimas épocas, confirmando que la combinación de técnicas implementadas permitió mejorar la capacidad predictiva y la robustez del modelo.

La comparación de las tres arquitecturas revela una evolución clara en términos de estabilidad y capacidad de generalización. En el modelo inicial, aunque la reducción de la pérdida y del MAE es rápida, la separación entre las curvas de entrenamiento y validación indica que el modelo no logra adaptarse de forma adecuada a datos no vistos. Esto se traduce en una menor eficacia predictiva y en un posible riesgo de sobreajuste si se prolongara el entrenamiento.

Con la introducción de técnicas de regularización y *dropout* en la arquitectura intermedia, se observa una mejora significativa: la distancia entre las curvas se reduce y el descenso del error se mantiene de manera más estable. Si bien la convergencia es más lenta que en el primer modelo, este comportamiento es deseable al implicar un aprendizaje más gradual y robusto, evitando que el modelo memorice patrones específicos del conjunto de entrenamiento.

Finalmente, el modelo avanzado muestra el comportamiento más equilibrado. La brecha entre entrenamiento y validación es mínima, y las métricas en validación alcanzan los valores más bajos, lo que confirma que la estrategia aplicada -incluyendo el escalado de la variable objetivo y el ajuste progresivo del *learning rate*- resultó determinante para optimizar el rendimiento. Estas mejoras se reflejan especialmente en la tendencia descendente del MAE, que evidencia un incremento notable en la precisión de las predicciones y una capacidad superior para generalizar.

En conclusión, el avance desde un modelo simple hacia arquitecturas más complejas no solo redujo el error, sino que también permitió alcanzar una mayor estabilidad y evitar el sobreajuste. El modelo final se posiciona como la opción más robusta y eficiente, consolidando la relevancia del preprocesamiento avanzado y del ajuste de hiperparámetros en la construcción de soluciones predictivas precisas.

5.2.5.4. Conclusiones sobre el uso de redes neuronales

El entrenamiento de modelos basados en redes neuronales para la predicción del precio de alojamientos turísticos ha permitido explorar un enfoque flexible y potente, capaz de capturar patrones complejos y relaciones no lineales entre las variables predictoras. A lo largo del proceso se han probado distintas configuraciones combinando diferentes arquitecturas para dichas redes neuronales, ajustando el número de capas, el tamaño de las neuronas, las técnicas de regularización y el aprendizaje dinámico, con el fin de mejorar progresivamente el rendimiento del modelo.

Uno de los hallazgos clave ha sido la importancia de la normalización previa de las variables, incluyendo la variable objetivo. Escalar el precio con *StandardScaler* antes del entrenamiento y desescalarlo posteriormente durante la predicción ha demostrado facilitar la convergencia del modelo y reducir los errores medios absolutos, especialmente en configuraciones más profundas. Igualmente, el uso combinado de *regularización L2*, *dropout* y estrategias de

parada anticipada ha contribuido a evitar el sobreajuste, estabilizando así el entrenamiento y permitiendo obtener modelos con mayor capacidad de generalización.

Aunque es cierto, que, a pesar de estos avances, el rendimiento final de la red neuronal más optimizada no ha conseguido superar al modelo basado en Random Forest, que ha demostrado una capacidad más robusta para modelar la variable objetivo en este problema concreto. Las redes neuronales han sido especialmente sensibles a la selección de hiperparámetros y han requerido más tiempo de ajuste y entrenamiento, lo que refuerza la necesidad de procesos de validación más exhaustivos y posiblemente el uso de técnicas de optimización automática como búsqueda en malla o algoritmos bayesianos.

6. Análisis y comparación de modelos

Este apartado tiene como objetivo comparar el rendimiento de los distintos modelos de predicción desarrollados a lo largo del proyecto. Concretamente, se analizan los resultados obtenidos por la **Regresión Lineal**, la **Regresión Ridge**, el modelo **XGBoost**, el modelo de **Random Forest**, y tres versiones progresivamente refinadas de **Redes Neuronales Artificiales**. Todos los modelos fueron entrenados con el mismo conjunto de variables predictoras, orientados a estimar el **precio de una habitación de hotel** a partir de sus características específicas (reputación, ubicación, servicios, entre otros).

Con el fin de evaluar la calidad predictiva de cada modelo, se han calculado métricas estándar de regresión: el **error absoluto medio (MAE)**, el **error cuadrático medio (MSE)**, la **raíz del error cuadrático medio (RMSE)** y el coeficiente de determinación **R²**, que indica la proporción de varianza explicada por el modelo.

6.1. Comparativa de métricas de evaluación

La Tabla 7 resume las métricas de evaluación obtenidas para cada uno de los modelos implementados en el estudio. A partir de estos resultados, se aprecia que existen variaciones significativas entre los modelos lineales, los algoritmos basados en árboles y las arquitecturas neuronales, lo que justifica el análisis detallado que se presenta.

Tabla 7. Comparativa de resultados en diferentes modelos

Modelo	MAE	MSE	RMSE	R ²
Regresión Lineal	67,91	8097,85	89,99	0,46
Regresión Ridge	67,91	8097,85	89,99	0,46
XGBoost	47,13	4186,16	64,70	0,72
Random Forest	27,82	1740,09	41,71	0,88
Red Neuronal	39,94	3253,07	57,04	0,78
Red Neuronal Mejorada	41,24	3855,65	62,09	0,74
Red Neuronal Final	35,66	2566,17	50,66	0,83

Fuente: elaboración propia

Para valorar el rendimiento de los modelos de regresión se han utilizado cuatro métricas habituales en este tipo de problemas. El **MAE** (Mean Absolute Error) mide el error medio absoluto entre las predicciones del modelo y los valores reales. Es decir, calcula cuánto se desvía, de media, la predicción con respecto al valor correcto, sin tener en cuenta el signo del error. El **MSE** (Mean Squared Error) sigue la misma idea, pero eleva al cuadrado esas diferencias antes de hacer la media, por lo que penaliza más los errores grandes. A partir de ahí, se calcula el **RMSE** (Root Mean Squared Error), que es simplemente la raíz cuadrada del MSE, y tiene la ventaja de que está expresado en las mismas unidades que la variable que queremos predecir (en este caso, euros). Por último, el **R²** (coeficiente de determinación) indica qué porcentaje de la variabilidad del precio se explica por el modelo. Cuanto más cercano esté a 1, mejor será el ajuste, ya que significará que el modelo capta gran parte de la información relevante para hacer buenas predicciones.


Del análisis se observa que tanto el modelo de Random Forest como la Red Neuronal Final son los que obtienen mejores resultados globales. En concreto, el modelo Random Forest presenta el **menor MAE (27,82)** y **menor RMSE (41,71)**, además de un **coeficiente R² de 0,88**, lo que indica un excelente ajuste al conjunto de datos. Por su parte, la Red Neuronal Final logra también un **elevado R² de 0,82**, junto con un **RMSE de 50,66**, lo cual confirma su capacidad para generalizar y reducir el error, superando con claridad a las versiones anteriores de redes neuronales.

Los modelos lineales (Regresión Lineal y Ridge), en cambio, presentan un rendimiento claramente inferior, con valores de MAE y RMSE más elevados y un coeficiente R² alrededor de 0.45, lo cual sugiere que no son capaces de capturar adecuadamente las relaciones no lineales presentes en el conjunto de datos.

6.2. Visualización de predicciones y selección final

A continuación, en la Figura 17, se presenta una visualización gráfica que compara el **valor real del precio** de una instancia seleccionada aleatoriamente frente a las predicciones de cada modelo. Esta comparación cualitativa permite evaluar el grado de ajuste a nivel individual:

Figura 17. Comparación de predicción de modelos con valor real de precio



Fuente: elaboración propia

Como se aprecia en la gráfica, tanto Random Forest como la Red Neuronal Final logran predicciones próximas al valor real (198 €), mientras que modelos como Regresión Lineal y Ridge **sobreestiman** considerablemente el precio, alcanzando valores cercanos a los 280 €. Las primeras versiones de la red neuronal presentan también desviaciones apreciables, lo cual refuerza la idea de que el proceso de mejora del modelo ha sido efectivo.

Teniendo en cuenta tanto las métricas cuantitativas como la validación visual, se concluye que los dos modelos más sólidos son Random Forest y la Red Neuronal Final. La elección entre ambos dependerá de criterios adicionales como la interpretabilidad, la velocidad de predicción en producción o la robustez ante nuevos datos, si bien en este trabajo se propone mantener ambos como modelos candidatos preferentes, siendo la red neuronal final la más adecuada en entornos donde el despliegue de soluciones basadas en aprendizaje profundo sea viable.

7. Código fuente y datos analizados

Con el propósito de garantizar la **trazabilidad, reproducibilidad y validación** de los resultados obtenidos en este Trabajo de Fin de Máster, se ha habilitado un **repositorio central accesible a través de la siguiente URL:**

https://drive.google.com/drive/folders/1ngnrZ9OI_WlPyBhvnPnGV7vs2p9D-NfU?usp=sharing

Este repositorio actúa como **hub principal del proyecto**, concentrando todos los recursos necesarios para replicar el flujo completo de trabajo, desde la preparación de datos hasta el entrenamiento y evaluación de modelos predictivos. Su organización sigue buenas prácticas de programación, asegurando la claridad y la escalabilidad del proyecto.

7.1. Código fuente

El código desarrollado para las diferentes fases del proyecto —limpieza, análisis exploratorio, modelado predictivo y generación de visualizaciones— está estructurado en carpetas específicas que facilitan la navegación:

- **Carpeta Notebooks/:** incluye los cuadernos Jupyter utilizados durante el desarrollo experimental:
 - `EDA_y_analisis.ipynb`: análisis exploratorio y visualización inicial.
 - `Entrenamiento_y_comparativa.ipynb`: ajuste, entrenamiento y evaluación de modelos.
 - `manipulacion_para_modelado.ipynb`: transformaciones para el preprocesamiento y modelado.
- **Carpeta Modelos/:** contiene los modelos entrenados en formato `.pkl`, organizados por tipología:
 - **ML/:** modelos de *machine learning* (Regresión Lineal, Ridge, Random Forest, XGBoost).
 - **Redes_neuronales/:** arquitecturas de redes neuronales (versión simple, mejorada y final).

Además, se ha incorporado un archivo `requirements.txt` que recoge las dependencias del proyecto, permitiendo la creación de entornos virtuales y la replicación del análisis en condiciones controladas.

7.2.Datos Analizados

Los conjuntos de datos empleados en este trabajo fueron proporcionados con fines exclusivamente académicos para la realización del TFM. Por motivos de **tamaño, permisos de uso y buenas prácticas en protección de datos**, no se incluyen en el repositorio ni se comparten públicamente.


No obstante, se han documentado en los notebooks las operaciones aplicadas durante la fase de preprocesamiento y análisis, de modo que cualquier usuario con acceso a datos equivalentes pueda reproducir el flujo completo siguiendo la estructura descrita en este proyecto.

7.3.Estructura general del repositorio

La organización del repositorio sigue una estructura modular y jerárquica para asegurar la claridad en la localización de componentes. En la Figura 18 podemos observar esta jerarquía de los archivos.

Esta estructura permite localizar fácilmente cada componente del proyecto, desde los scripts fuente hasta las salidas gráficas y los modelos entrenados. Además, el archivo `README.md` principal ofrece una guía básica de uso, instrucciones para la ejecución del código y un resumen de los objetivos del trabajo.

Figura 18. Esquema *del repositorio*



Fuente: elaboración propia

8. Conclusiones

El presente trabajo ha alcanzado el objetivo general de desarrollar y aplicar un modelo analítico avanzado capaz de predecir el precio de alojamientos turísticos a partir de un conjunto de variables heterogéneas, cumpliendo con una secuencia metodológica progresiva que abarca desde la limpieza y análisis exploratorio de datos hasta la implementación y evaluación de modelos predictivos basados en *machine learning*.

En relación con los objetivos específicos planteados, se ha dado respuesta integral a cada uno de ellos. En primer lugar, se abordó el **OE1**, analizando la problemática asociada a la estimación de precios y determinando qué variables resultaban más influyentes. Este análisis incluyó factores estructurales, reputacionales y de ubicación, cuya importancia se confirmó en fases posteriores. De igual modo, el **OE2** se materializó mediante la revisión de literatura y trabajos previos, que proporcionaron un marco comparativo para orientar la selección de modelos.

La definición clara del alcance y de los criterios metodológicos (**OE3**) permitió estructurar el proceso en etapas coherentes, lo que facilitó la preparación y transformación del conjunto de datos (**OE4**) mediante procedimientos como imputación de valores nulos, codificación *One-Hot* y normalización, garantizando su calidad y adecuación para modelos sensibles a la escala de las variables. Posteriormente, se dio cumplimiento al **OE5** con la implementación de diferentes modelos predictivos, desde enfoques clásicos como la regresión lineal hasta algoritmos más avanzados como Random Forest, XGBoost y redes neuronales en TensorFlow, incorporando ajustes de hiperparámetros en cada caso.

La interpretación crítica de los resultados (**OE6**) constituyó una fase clave, ya que permitió contrastar la eficacia de los modelos en términos de precisión y robustez, utilizando métricas como MAE, RMSE y R^2 . Finalmente, el **OE7** se concretó en la elaboración de conclusiones que no solo integran los hallazgos más relevantes, sino que también aportan criterios orientados a la mejora de futuros sistemas predictivos en el sector hotelero.

8.1. Interpretación de resultados y comparación de modelos

Los resultados obtenidos tras la implementación y evaluación de los modelos reflejan una clara evolución en términos de precisión y capacidad predictiva a medida que se incorporaron técnicas más complejas. En primer lugar, tanto la regresión lineal como el modelo Ridge presentaron un rendimiento equivalente, con un R^2 de 0,46 y un *RMSE* cercano a 89,99. Esta similitud se explica por la depuración previa realizada sobre el conjunto de datos, especialmente mediante la eliminación de valores atípicos extremos que, en escenarios iniciales, habrían favorecido a métodos con regularización como Ridge frente a la regresión ordinaria. La reducción de la influencia de dichos *outliers* neutralizó esta ventaja, lo que condujo a que ambos enfoques ofrecieran métricas idénticas.

El modelo XGBoost representó un avance significativo con respecto a los métodos lineales, alcanzando un R^2 de 0,72 y un *RMSE* de 64,70. Esta mejora se justifica por la capacidad del algoritmo para modelar relaciones no lineales y manejar interacciones complejas mediante la técnica de *boosting* secuencial, que reduce el sesgo acumulado y optimiza el ajuste progresivamente.

Posteriormente, el modelo Random Forest destacó por ofrecer el mejor rendimiento global, con un R^2 de 0,88 y un *RMSE* de 41,71, lo que evidencia su capacidad para minimizar la varianza mediante la técnica de *bagging* y la agregación de múltiples árboles de decisión. Su comportamiento robusto frente a la multicolinealidad y la heterogeneidad del conjunto de variables lo posiciona como la alternativa más estable y eficiente para el problema analizado.

Por su parte, la red neuronal mostró un comportamiento progresivamente mejorado a medida que se ajustaron sus hiperparámetros. En las primeras configuraciones, los valores de R^2 se situaban en torno a 0,74, pero tras la incorporación de arquitecturas más profundas, mecanismos de regularización mediante *dropout* y estrategias como *early stopping*, la versión final alcanzó un R^2 de 0,83 y redujo el *RMSE* hasta 50,66. Estos resultados confirman que, si bien las redes neuronales requieren una fase de ajuste más intensiva, su potencial predictivo es elevado en escenarios con alta interacción entre variables.

En términos interpretativos, el análisis de importancia de variables confirma que factores como la reputación global y el área de la habitación tienen un peso determinante en la

estimación del precio, lo cual resulta coherente con la lógica del sector turístico y refuerza la validez del modelo propuesto.

8.2. Hiperparámetros clave

En la optimización de modelos, se evaluaron diferentes configuraciones con el objetivo de mejorar la precisión y la estabilidad. En el caso de la regresión Ridge, se empleó un valor de $\alpha=1.0$, manteniendo un ajuste moderado que evitara sobreajuste sin penalizar excesivamente los coeficientes. Para XGBoost, la configuración óptima incluyó $n_estimators=100$ y $learning_rate=0.1$, valores que favorecieron un equilibrio entre capacidad predictiva y coste computacional. El modelo Random Forest se ajustó con $n_estimators=10$ y $random_state=42$, priorizando la simplicidad y la rapidez en la ejecución, sin comprometer el rendimiento.

Por su parte, la red neuronal se diseñó en TensorFlow con una arquitectura final compuesta por tres capas densas de 256, 128 y 64 neuronas, activación ReLU y salida lineal. Se incorporaron mecanismos de regularización mediante *dropout* (0,3 en la primera capa oculta y 0,2 en la segunda), un *learning_rate* inicial de $1e-3$ con optimizador Adam, un tamaño de lote de 32 y *early stopping* para prevenir el sobreajuste. Estas decisiones contribuyeron a reducir el error y mejorar el R^2 , demostrando la importancia de un ajuste cuidadoso en este tipo de modelos.

8.3. Reflexión final sobre eficiencia y coste computacional

Más allá del análisis de precisión, resulta fundamental considerar la eficiencia computacional y los requerimientos asociados al almacenamiento, dado que estos factores influyen directamente en la escalabilidad y viabilidad práctica del modelo. En este sentido, se observa que el modelo Random Forest, a pesar de ser el más preciso ($R^2 = 0,88$), presenta el mayor coste computacional y un tamaño de archivo considerablemente superior al resto (`random_forest_model.pkl` ≈ 484 MB). Este aspecto implica mayores tiempos de entrenamiento, así como limitaciones potenciales en escenarios donde la memoria disponible sea un recurso crítico.

Por el contrario, la red neuronal final, con un rendimiento competitivo ($R^2 = 0,83$), ofrece un tamaño significativamente menor en su versión optimizada (`rn_model_final.h5` ≈ 703 KB), lo que la convierte en una opción más manejable desde la perspectiva del despliegue, si bien su entrenamiento demanda recursos de procesamiento intensivos, especialmente en GPU.

Los modelos lineales, como la regresión simple y Ridge, destacan por su mínima carga computacional y tamaño (más o menos 3 KB), lo que garantiza tiempos de ejecución prácticamente instantáneos. Sin embargo, su baja capacidad para capturar relaciones no lineales se traduce en un rendimiento limitado ($R^2 = 0,46$). Finalmente, XGBoost se presenta como una alternativa equilibrada, combinando una precisión aceptable ($R^2 = 0,72$) con un tamaño intermedio (≈ 482 KB) y un tiempo de entrenamiento razonable, lo que refuerza su utilidad en entornos que requieran un compromiso entre eficiencia y exactitud.

En conclusión, la selección del modelo óptimo no debe basarse únicamente en métricas predictivas, sino también en el análisis del coste computacional y de los recursos asociados. Así, mientras Random Forest constituye la mejor opción en términos de exactitud, la red neuronal y XGBoost emergen como alternativas viables en contextos donde la escalabilidad y la eficiencia operativa resulten prioritarias. En la Tabla 9, se puede ver un resumen de los elementos más importantes del trabajo

Tabla 8. *Tabla de métricas de los modelos entrenados*

Modelo	MAE	MSE	RMSE	Tamaño (MB)	Tiempo Entrenamiento	Coste Computacional
Regresión Lineal	0,46	67,91	89,99	0,003	Muy bajo	Bajo
Regresión Ridge	0,46	67,91	89,99	0,003	Muy bajo	Bajo
XGBoost Regressor	0,72	47,13	64,70	0,48	Medio	Medio
Random Forest Regressor	0,88	27,82	41,71	484	Alto	Medio
Red Neuronal Final	0,83	35,66	50,66	0,70	Alto	Medio

Fuente: elaboración propia

9. Limitaciones y prospectiva

Tras el análisis detenido de las conclusiones expuestas en el presente estudio, resulta imprescindible abordar a continuación las principales limitaciones que éste ha presentado, con el fin de ofrecer una visión crítica y rigurosa de su alcance. En este apartado se examinarán tanto las restricciones de alcance como los recursos que han podido condicionar los hallazgos, así como las implicaciones de dichos sesgos sobre la validez de los resultados. Asimismo, se propondrán líneas de investigación futuras que permitan superar las deficiencias identificadas, profundizar en aspectos aún poco explorados y consolidar el conocimiento generado, contribuyendo así al avance progresivo del campo de estudio.

9.1. Limitaciones

A pesar de los resultados obtenidos, es importante señalar una serie de limitaciones que han condicionado parcialmente el desarrollo de este trabajo. En primer lugar, cabe destacar que el conjunto de datos utilizado fue proporcionado por una empresa privada, lo que supone una restricción en cuanto a su acceso público y transparencia. Si bien se ha trabajado con datos reales y relevantes, la opacidad respecto al proceso exacto de recogida y validación de dicha información introduce posibles incertidumbres sobre la calidad del dato y limita su replicabilidad por parte de terceros.

Otro aspecto a considerar es el tamaño de la muestra. El *dataset* final contenía registros de aproximadamente 2.200 hoteles, lo cual resulta suficiente para aplicar y evaluar distintos modelos, pero podría considerarse modesto si se busca una generalización robusta a nivel nacional o internacional. Además, el rango temporal de los datos está restringido a un período de unos seis meses, lo que obedece a que los datos comenzaron su extracción desde la Booking.com a partir de septiembre de 2024. Este tiempo reducido supone una complicación de cara a una mejor generalización del algoritmo, pues no aprenderá el comportamiento de fechas que no se encuentren en el periodo, como, por ejemplo, el mes de mayo. Esto afecta a la posibilidad de incorporar efectos estacionales o tendencias de largo plazo.

Estas limitaciones, si bien no comprometen la validez del análisis realizado, deben tenerse en cuenta a la hora de interpretar los resultados y valorar su extensión a otros contextos. Asimismo, abren la puerta a mejoras futuras, especialmente si se consigue acceso a *datasets*

más amplios, públicos y longitudinales. Es por ello que en el siguiente apartado de este capítulo van a presentarse algunas ideas para diferentes trabajos futuros que pueden ampliar el alcance del ya realizado.

9.2.Trabajo futuro

El trabajo realizado constituye una base sólida sobre la que se pueden desarrollar múltiples líneas de investigación y aplicación. En un entorno profesional, los modelos predictivos contruidos podrían integrarse en herramientas de ayuda a la toma de decisiones para empresas del sector hotelero, permitiendo ajustar precios en función de variables como ubicación, reputación o características del alojamiento. Este tipo de sistemas podría incorporarse, por ejemplo, en plataformas de *revenue management* o *dashboards* personalizados para gestores turísticos. Esto podría suponer un gran avance para los gestores de los establecimientos en cómo afrontan sus estrategias de precios.

Desde un punto de vista técnico, una evolución natural del modelo sería incorporar análisis temporales mediante técnicas de series temporales, lo que permitiría estudiar la evolución de precios a lo largo del año y detectar patrones estacionales. Si además esto es capaz de coordinarse con otros parámetros como la ubicación se puede estar hablando de un modelo muy potente, pues no es lo mismo la estrategia de precios de un hotel en Pamplona el 7 de julio que un hotel en Madrid para la misma fecha. Para ello sería necesario contar con datos históricos más extensos, que incluyan variaciones de precios y reputación en distintos momentos del año.

Otra vía interesante sería el uso de técnicas de aprendizaje no supervisado, como el clustering, con el fin de agrupar hoteles por similitud geográfica, reputacional o de servicios ofrecidos. Esto permitiría descubrir patrones emergentes que no dependen de una variable objetivo-explicita, y que podrían enriquecer los análisis de segmentación de mercado.

Finalmente, se podrían implementar visualizaciones más avanzadas, como mapas de coropletas que representen la distribución geográfica de precios o reputación.

Por último, se propone como trabajo futuro el desarrollo de una aplicación gráfica destinada a los gestores hoteleros que permita predecir el precio que debe tener un hotel según las

características que se determinen. Es decir, transformar la investigación y los resultados de este trabajo en un software palpable con utilidad real en el mundo hotelero.

Estas líneas futuras no solo ampliarían el alcance del trabajo actual, sino que también reforzarían su aplicabilidad en entornos reales, mejorando la transparencia, usabilidad y valor estratégico de los sistemas predictivos basados en datos en el sector turístico.

REFERENCIAS BIBLIOGRÁFICAS

- Abiodun, O. I., Jantan, A., Omolara, A. E., Dada, K. V., Mohamed, N. A., & Arshad, H. (2018). State-of-the-art in artificial neural network applications: A survey. *Heliyon*, 4(11).
- Abrate, G., Fraquelli, G., & Viglia, G. (2011). Dynamic pricing strategies: Evidence from European hotels. *International Journal Of Hospitality Management*, 31(1), 160-168.
<https://doi.org/10.1016/j.ijhm.2011.06.003>
- Abrate, G., & Viglia, G. (2016). Strategic and tactical price decisions in hotel revenue management. *Tourism Management*, 55, 123-132.
<https://doi.org/10.1016/j.tourman.2016.02.006>
- Agmapisarn, C. (2014). A hedonic pricing analysis of hotel room rates in Bangkok. *ABAC Journal*, 34(2), 1.
- Anshori, M. Y., Katias, P., Herlambang, T., Meutia, N. S., Othman, Z. B., & Azmi, M. S. (2025). Predicting Hotel Revenue Using Gradient Boosting Regression and Support Vector Regression: A Comparative Analysis. <https://doi.org/10.21203/rs.3.rs-6910156/v1>
- Catalina, P. T. L., Andrés, H. G. J., & Esteban, V. B. D. (2025). *Principales determinantes y su impacto en la ocupación hotelera: el caso del Hotel Estelar La Fontana, Bogotá (2019-2023)*.
<https://hdl.handle.net/20.500.14625/41946>
- Chau, K. W., & Chin, T. L. (2003). A critical review of literature on the hedonic price model. *International Journal for Housing Science and its applications*, 27(2), 145-165.

Coenders, G., Espinet, J.M. and Saez, M. Predicting Random Level and Seasonality of Hotel Prices-A Structural Equation Growth Curve Approach. (2001). *University Of Girona, Department Of Economics, Girona, working paper no. 1.*

Diana-Jens, P., & Ruibal, A. R. (2015). Online reputation and its impact on hotel pricing strategies. *Cuadernos de Turismo*, 36, 129-456.
<https://www.cabdirect.org/abstracts/20153292785.html>

Dommelen, T. V. (2021). *Hotel room demand forecasting: time series forecasting using SARIMA, LSTM and Prophet* (Doctoral dissertation, ETSI_Informatica).
<https://oa.upm.es/70187/>

Ert, E., Fleischer, A., & Magen, N. (2016). Trust and reputation in the sharing economy: The role of personal photos in Airbnb. *Tourism Management*, 55, 62-73.
<https://doi.org/10.1016/j.tourman.2016.01.013>

Espinet, J., Saez, M., Coenders, G., & Fluvà, M. (2003). Effect on Prices of the Attributes of Holiday Hotels: A Hedonic Prices Approach. *Tourism Economics*, 9(2), 165-177.
<https://doi.org/10.5367/000000003101298330>

Giannoni, S., Petit, S., Peypoch, N., & Zekan, B. (2024). Tourism economics development beyond the COVID-19 crisis: The eight International Association for Tourism Economics (IATE) conference. *Tourism Economics*, 30(4), 809-812.
<https://doi.org/10.1177/13548166241248243>

Hu, T., & Song, H. (2022). Analysis of influencing factors and distribution simulation of budget hotel room pricing based on big data and machine learning from a spatial perspective. *Sustainability*, 15(1), 617. <https://doi.org/10.3390/su15010617>

- Ivanov, S., & Zhechev, V. (2012). Hotel revenue management—a critical literature review. *Tourism: an international interdisciplinary journal*, 60(2), 175-197. <https://dx.doi.org/10.2139/ssrn.1977467>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning. En *Springer texts in statistics*. <https://doi.org/10.1007/978-1-4614-7138-7>
- Kosten, L. (1960). Een mathematisch model voor een reserveringsprobleem. *Statistica Neerlandica*, 14(1), 85-94. <http://dx.doi.org/10.1111/j.1467-9574.1960.tb00893.x>
- Lamest, M., & Brady, M. (2018). Data-focused managerial challenges within the hotel sector. *Tourism Review*, 74(1), 104-115. <https://doi.org/10.1108/tr-03-2017-0064>
- Littlewood, K. (1972). Forecasting and control of passenger bookings. *The Airline Group of the International Federation of Operational Research Societies*, 12, 95-117. <https://cir.nii.ac.jp/crid/1572543026074888192>
- López-Gamero, M. D., Molina-Azorín, J. F., Pereira-Moliner, J., & Pertusa-Ortega, E. M. (2023). Agility, innovation, environmental management and competitiveness in the hotel industry. *Corporate Social Responsibility and Environmental Management*, 30(2), 548-562. <https://doi.org/10.1002/csr.2373>
- Lu, T. (2025, February). The Application of Ridge Regression, Random Forest and Mean-Variance Model in Portfolio Optimization. In *International Workshop on Navigating the Digital Business Frontier for Sustainable Financial Innovation (ICDEBA 2024)* (pp. 592-598). Atlantis Press. https://doi.org/10.2991/978-94-6463-652-9_62

- Modjo, M. I., & Wibowo, A. S. (2023). Pricing Strategy for a Smart-Tourist Area: Does Location Matters?. In *E3S Web of Conferences* (Vol. 426, p. 02061). EDP Sciences. <https://doi.org/10.1051/e3sconf/202342602061>
- Moro, S., Rita, P., & Oliveira, C. (2017). Factors Influencing Hotels' Online Prices. *Journal of Hospitality Marketing & Management*, 27(4), 443–464. <https://doi.org/10.1080/19368623.2018.1395379>
- Nava-Yazdani, E. (2024). Ridge Regression for Manifold-valued Time-Series with Application to Meteorological Forecast. *arXiv preprint arXiv:2411.18339*. <https://doi.org/10.48550/arXiv.2411.18339>
- Öğüt, H., & Taş, B. K. O. (2011). The influence of internet customer reviews on the online sales and prices in hotel industry. *Service Industries Journal*, 32(2), 197-214. <https://doi.org/10.1080/02642069.2010.529436>
- Oliveira, F. B., Silva-Filho, M. W., Barbosa, G. A., Freitas, J. P., Penna, C., & Miranda, P. B. C. (2025). Machine Learning and Time Series Analysis to Forecast Hotel Room Prices. En *Lecture notes in computer science* (pp. 358-371). https://doi.org/10.1007/978-3-031-79035-5_25
- Phan, P. D. D., Anh, M. A. N. N. M., & Nguyen, B. H. H. (2024). Using linear regression analysis to predict energy consumption. <https://doi.org/10.21203/rs.3.rs-4590592/v1>
- Ropero, M. A. (2011). Dynamic Pricing Policies of Hotel Establishments in an Online Travel Agency. *Tourism Economics*, 17(5), 1087-1102. <https://doi.org/10.5367/te.2011.0082>

- Rouhani, M. M., & Farrokh, E. (2025). TBM performance prediction based on XGBoost models: a case study of the ghomrud water conveyance tunnel (Lots 3 and 4). *Bulletin of Engineering Geology and the Environment*, 84(6), 304. <https://doi.org/10.1007/s10064-025-04338-4>
- Sánchez-Pérez, M., Illescas-Manzano, M. D., & Martínez-Puertas, S. (2019). Modeling hotel room pricing: A multi-country analysis. *International Journal of Hospitality Management*, 79, 89-99. <https://doi.org/10.1016/j.ijhm.2018.12.014>
- Shehhi, M. A., & Karathanasopoulos, A. (2019). Forecasting hotel room prices in selected GCC cities using deep learning. *Journal Of Hospitality And Tourism Management*, 42, 40-50. <https://doi.org/10.1016/j.jhtm.2019.11.003>
- Silvia-Patricia, D., Camelia-Elena, C., & Iulian, P. (2024). PRICING STRATEGIES IN HOSPITALITY. ANALYZING COURTYARD BY MARRIOTT'S POLICIES AND THEIR IMPACT ON OCCUPANCY RATES. *Romanian Economic and Business Review*, 19(4), 443. <https://rebe.rau.ro/REBE-WI24.pdf#page=43>
- Sparks, B. A., & Browning, V. (2011). The impact of online reviews on hotel booking intentions and perception of trust. *Tourism Management*, 32(6), 1310-1323. <https://doi.org/10.1016/j.tourman.2010.12.011>
- Taye, E. A., Woubet, E. Y., Hailie, G. Y., Arage, F. G., Zerihun, T. E., Zegeye, A. T., ... & Kassaw, A. T. (2025). Application of the random forest algorithm to predict skilled birth attendance and identify determinants among reproductive-age women in 27 Sub-Saharan African countries; machine learning analysis. *BMC Public Health*, 25(1), 901. <https://doi.org/10.1186/s12889-025-22007-9>

- Vermeulen, I. E., & Seegers, D. (2008). Tried and tested: The impact of online hotel reviews on consumer consideration. *Tourism Management*, 30(1), 123-127. <https://doi.org/10.1016/j.tourman.2008.04.008>
- Viverit, L., Heo, C. Y., Pereira, L. N., & Tiana, G. (2023). Application of machine learning to cluster hotel booking curves for hotel demand forecasting. *International Journal of Hospitality Management*, 111, 103455. <https://doi.org/10.1016/J.IJHM.2023.103455>
- Wang, X., Sun, J., & Wen, H. (2019). Tourism seasonality, online user rating and hotel price: A quantitative approach based on the hedonic price model. *International Journal of Hospitality Management*, 79, 140-147. <https://doi.org/10.1016/j.ijhm.2019.01.007>
- Xie, K. L., Zhang, Z., & Zhang, Z. (2014). The business value of online consumer reviews and management response to hotel performance. *International Journal Of Hospitality Management*, 43, 1-12. <https://doi.org/10.1016/j.ijhm.2014.07.007>
- Ye, Q., Law, R., & Gu, B. (2008). The impact of online user reviews on hotel room sales. *International Journal Of Hospitality Management*, 28(1), 180-182. <https://doi.org/10.1016/j.ijhm.2008.06.011>
- Zhang, D., & Niu, B. (2024). Leveraging online reviews for hotel demand forecasting: A deep learning approach. *Information Processing & Management*, 61(1), 103527. <https://doi.org/10.1016/j.ipm.2023.103527>
- Zhang, Z., Ye, Q., & Law, R. (2011). Determinants of hotel room price. *International Journal Of Contemporary Hospitality Management*, 23(7), 972-981. <https://doi.org/10.1108/09596111111167551>

Zheng, W., Li, C., & Deng, Z. (2024). Hotel demand forecasting with multi-scale spatiotemporal features. *International Journal Of Hospitality Management*, 123, 103895.
<https://doi.org/10.1016/j.ijhm.2024.103895>